PEC 2 – ESTADÍSTICA MULTIVARIANTE

Análisis multivariante

Alberto Torrejón Aquino

Ejercicio 1, Ejercicio 2 y Ejercicio 3

Master universitario en Bioinformática y Bioestadística

1. Ejercicio 1 (40 pt)

Tres grupos de pacientes distintos se trataron con tres diferentes pastillas para dormir. Una de ellas fue placebo. Se midió el resultado en horas de sueño (*efficacy*) y también una puntuación de los efectos secundarios *(sideeffect).* Otras variables que también se registraron son el sexo y la comorbilidad.



Los datos se han importado a R y se hallan en el archivo *sleep.Rdata.*

1.1 Realizar un resumen numérico y gráfico de los datos

Nos interesa saber si el diseño es balanceado y el número de observaciones por sexo y comorbilidad según el tratamiento.

Para poder conocer si el diseño es balanceado tenemos que realizar tablas cruzadas para verificar si tenemos el mismo número de observaciones por combinación de niveles de los factores de interés (Tratamiento, sexo y comorbilidad).

Para ello, realizamos una tabla de contingencia en R mediante la función table(), lo que permite visualizar las frecuencias de observaciones según los niveles combinados de factores

table(sleep$group, sleep$gender, sleep$comorbidity)

```
, ,  = No

        male female
treat0    3      1
treat1    0      5
treat2    3      2
```

```
, ,  = Yes

        male female
treat0    3      3
treat1    4      1
treat2    3      2
```

Resultados tabla de contingencia en RStudio

Podemos observar que el diseño experimental es desbalanceado, ya que no hay el mismo número de observaciones para todas las combinaciones de niveles de los factores.

Medias disgregadas para la variable efficacy en función de los factores.

Para estudiar cómo varía la eficacia (medida en horas de sueño) en función de los factores, se han calculado las medias disgregadas por tratamiento, sexo y comorbilidad mediante la función tapply() en R.

```
tapply(sleep$efficacy, sleep$group, mean)

treat0 treat1 treat2

4.21   5.21   6.93
```

Tapply nos permite ver las medias por cada grupo de tratamiento aplicados, cribando si ha sido el tratamiento 1, 2 o 3 y enfrentándolo a las medias correspondientes. En este caso, podemos ver como treat 0 tiene una menor eficacia comparado con treat 2. Tiene sentido asumir que el treat 0 es el que menor eficacia ha tenido debido a que sería el tratamiento placebo frente a treat 1 y treat 2 que presentan una mayor eficacia en términos de horas de sueño

Estudiar especialmente la relación entre las variables numéricas. ¿Están correlacionadas?

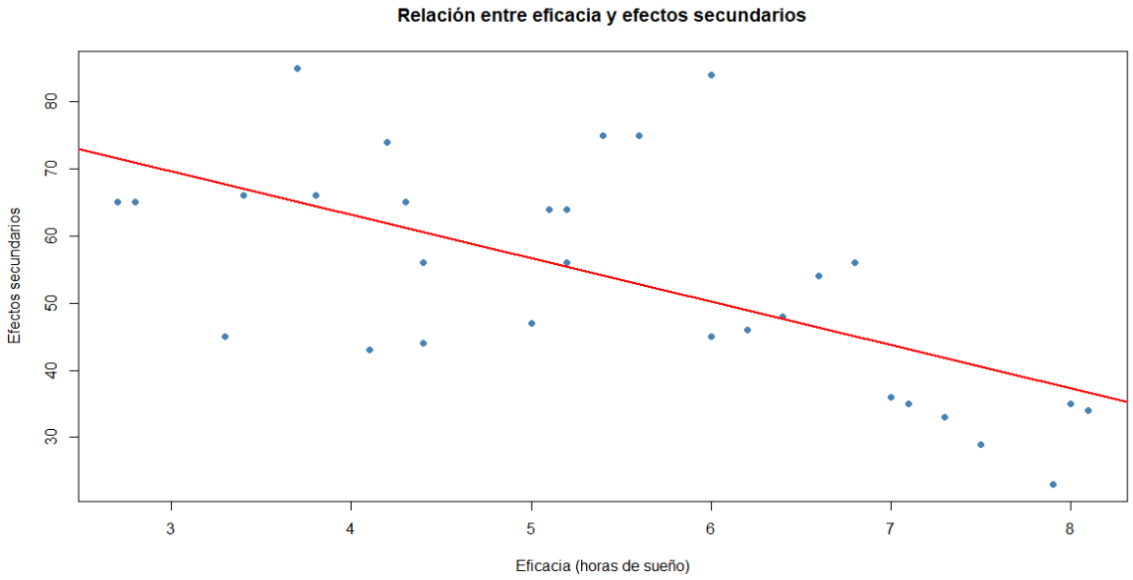
En este caso nos piden algo interesante a la hora de estudiar este conjunto de datos que sería una comparativa entre los datos numéricos (efficacy y sideffect), que son bastante interesantes a tener en cuenta a la hora de desarrollar un fármaco. Vemos con R studio cual es el valor de correlación que nos devuelve con el siguiente fragmento de código:

```
cor(sleep$efficacy, sleep$sideeffect)

-0,62
```

Podemos observar que tenemos una correlación negativa moderada. Esto, nos indica (no significa que confirme) que, a mayor eficacia del tratamiento, menores efectos secundarios.

Gráficos comparativos de las variables numéricas según los niveles de los factores, en especial el factor tratamiento.



Plot realizado en Rstudio sobre las variables numéricas de la base de datos sleep

1.2 Calcular el vector de medias, la matriz de covarianzas y la matriz de correlaciones de las dos variables respuesta conjuntamente según los niveles del factor *group*.

Código para la generación del vector de medias

```
aggregate(cbind(efficacy, sideeffect) ~ group, data = sleep, FUN = mean)
```

Cálculo de la matriz de covarianzas

```
sleep$group: treat0
            efficacy sideeffect
efficacy    1.687667  -9.558889
sideeffect -9.558889 150.233333
```

```
sleep$group: treat1
            efficacy sideeffect
efficacy    1.687667   -11.1200
sideeffect -11.120000   279.7333
```

```
sleep$group: treat2
            efficacy sideeffect
efficacy     0.64900  -10.59556
sideeffect -10.59556  242.62222
```

Resultados cálculo del matriz de covarianzas en Rstudio

Cálculo de matriz de correlaciones

```
sleep$group: treat0
            efficacy sideeffect
efficacy    1.0000000 -0.6003174
sideeffect -0.6003174  1.0000000
```

```
sleep$group: treat1
            efficacy sideeffect
efficacy    1.0000000 -0.5117871
sideeffect -0.5117871  1.0000000
```

```
sleep$group: treat2
            efficacy sideeffect
efficacy    1.0000000 -0.8443764
sideeffect -0.8443764  1.0000000
```

Resultados cálculo del matriz de correlaciones en Rstudio

Podemos observar que las matrices presentan correlación negativa en los tres tratamientos, observando que es especialmente elevada en el tratamiento 2 (-0,844). Los resultados muestran que los tratamientos más eficaces en este grupo se asocian con menor incidencia de efectos secundarios.

Calcular también la varianza generalizada, la varianza total y el coeficiente global $\eta^2 = 1 - |\mathbf{R}|$ para cada nivel por separado.

Una vez realizado el cálculo en R (Código en anexo de este documento), los resultados obtenidos los podemos resumir en la siguiente tabla:

Grupo	Varianza General	Varianza Total	$\eta^2 = 1 - \|\mathbf{R}\|$
Placebo	162.17	151.92	0.360
Tratamiento 1	348.44	281.42	0.262
Tratamiento 2	45.20	243.27	0713

Tabla resumen resultados ejercicio 1.2

Observamos que el tratamiento 1 presenta una mayor variabilidad, dando lugar a respuestas más heterogeneas en el tratamiento entre los pacientes. Por otro lado, el tratamiento 2 tiene una menor dispersion, pero una fuerte correlación entre eficacia y efectos secundarios. Esto, sugiere una relación lineal más clara entre ambas variables.

1.3 Estudiar la normalidad multivariante con el test de Mardia que se explica en el apéndice de este documento.

Calcular los estadísticos de asimetría $B_{1,P}$ y de kurtosis $B_{2,P}$. Calcular los estadísticos estandarizados $\gamma_{1,P}$ y $\gamma_{2,P}$ y sus correspondientes p-valores y decidir si admitimos la normalidad en las tres especies

Acompañar el test con un gráfico qq-plot de ajuste a la distribución ji-cuadrado de las distancias de Mahalanobis de los datos a la media en cada especie.

Para evaluar la normalidad multivariante de las variables numéricas en cada uno de los grupos de tratamiento, utilizamos el Test Mardia. Este test, estudia dos estadísticas principalmente:

Asimetría Multivariante $B_{1,P}$ y kurtosis multivariante $B_{2,P}$.

```
Grupo: 1
$b1p
[1] 0.666836

$b2p
[1] 5.264376

$gamma1p
[1] 1.111393

$pval_gamma1p
[1] 0.8924603

$gamma2p
[1] -1.08135

$pval_gamma2p
[1] 0.2795414
```

```
Grupo: 2
$b1p
[1] 0.8160702

$b2p
[1] 5.824124

$gamma1p
[1] 1.360117

$pval_gamma1p
[1] 0.8510964

$gamma2p
[1] -0.8600904

$pval_gamma2p
[1] 0.3897392
```

```
Grupo: 3
$b1p
[1] 0.4901162

$b2p
[1] 5.27839

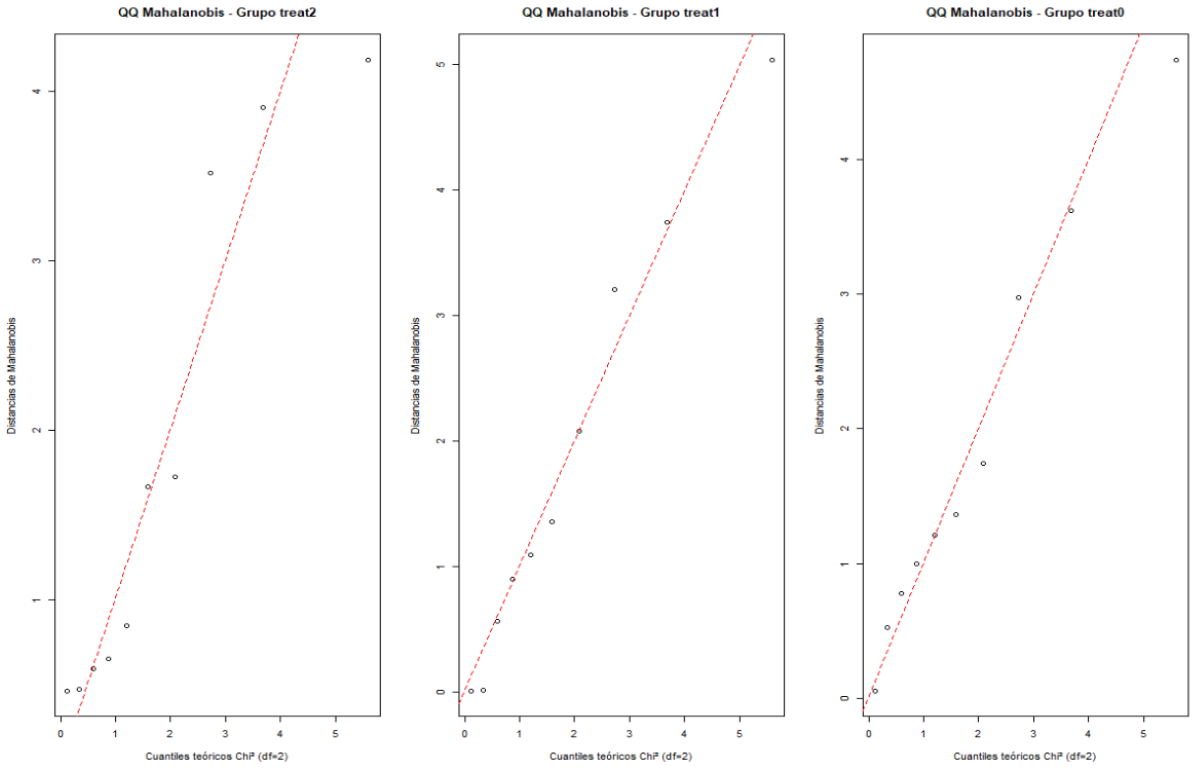
$gamma1p
[1] 0.8168603

$pval_gamma1p
[1] 0.9361735

$gamma2p
[1] -1.075811

$pval_gamma2p
[1] 0.2820119
```

En ninguno de los grupos se observa una asimetría significativa, ya que los p-valores asociados a $\gamma_{1,P}$ son todos superiores a 0.05. Tampoco se detecta una **kurtosis anómala**, ya que los valores de $\gamma_{2,P}$ también resultan no significativos en todos los grupos, por lo que se puede continuar con el análisis sin necesidad de transformar las variables ni usar métodos no paramétricos.



QQ-plot de las distancias de Mahalanobis

En los tres grupos, las distancias de Mahalanobis se alinean razonablemente con los cuantiles teóricos de una distribución chi-cuadrado con 2 grados de libertad. Esto, apoya la hipótesis de normalidad multivariante en los 3 tratamientos.

1.4 Repetir el estudio de la normalidad multivariante con la asimetría y la kurtosis multivariante de Mardia gracias a la función mvn del paquete MVN. La misma función permite el estudio univariante y también hace los gráficos.

Observar la coincidencia con los resultados del apartado anterior.

Test <chr>	Statistic <dbl>	p.value <dbl>
Mardia Skewness	1.7803844	0.7760691
Mardia Kurtosis	-0.5863925	0.5576118

Test <chr>	Statistic <dbl>	p.value <dbl>
Mardia Skewness	2.4223327	0.6585952
Mardia Kurtosis	-0.5932314	0.5530263

Test <chr>	Statistic <dbl>	p.value <dbl>
Mardia Skewness	2.9644374	0.5637943
Mardia Kurtosis	-0.3200712	0.7489144

Resultados función MVN

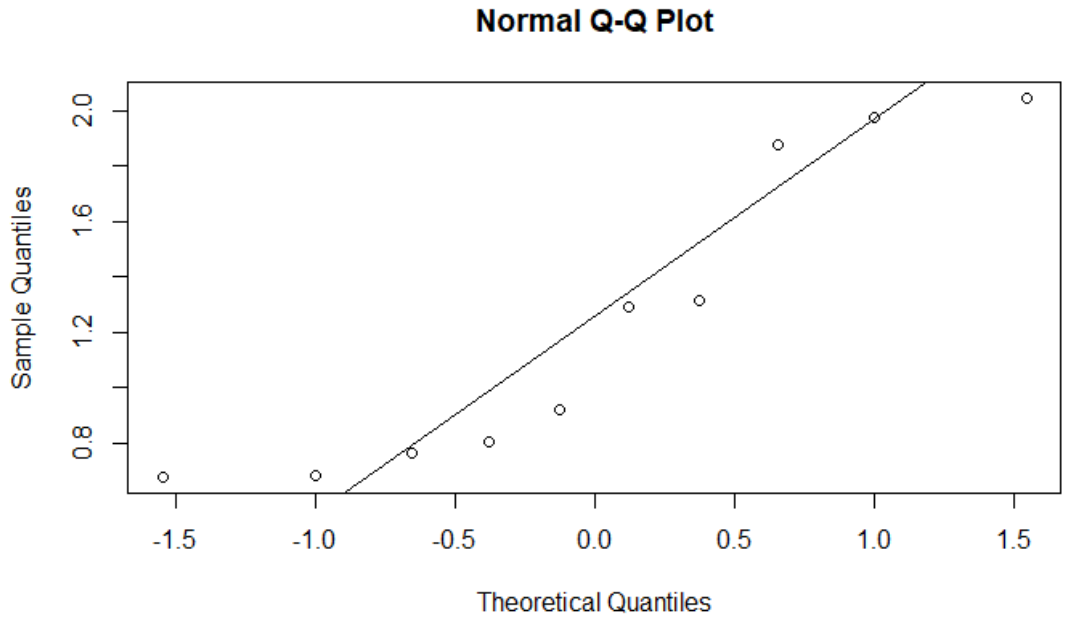
Aunque los valores numéricos de los estadísticos son diferentes, especialmente en la kurtosis debido al tipo de estandarización, los p-valores fueron consistentes en todos los casos (mayores a 0.05).

Por tanto, ambos métodos coinciden en la conclusión: no hay evidencia estadística para rechazar la normalidad multivariante en ninguno de los tres grupos de tratamiento.

1.5 Con el mismo fin que los dos apartados anteriores se puede utilizar la función *mardia* del paquete *psych*, sin embargo, los resultados son distintos ya que esta función utiliza la matriz de covarianzas insesgada.

Aplicamos la función mardia() del paquete psych con el mismo objetivo que en los apartados anteriores. Esta función calcula los estadísticos de asimetría y kurtosis multivariantes utilizando la matriz de covarianzas insesgada, a diferencia del cálculo manual o el realizado con el paquete MVN.

Los valores obtenidos fueron distintos en magnitud respecto a los apartados 1.3 y 1.4, lo cual es esperable por el método de estimación. Sin embargo, los resultados no fueron estadísticamente significativos, por lo que no se rechaza la hipótesis de normalidad multivariante en ninguno de los grupos.



Distribución de distancias de Mahalanobis (función mardia() del paquete psych)

1.6 Comparar las matrices de covarianzas de las tres especies con el test de la razón de verosimilitudes. También se puede utilizar el test M de Box

```
        Box's M-test for Homogeneity of Covariance Matrices

data:  sleep[, c("efficacy", "sideeffect")]
Chi-Sq (approx.) = 8.2014, df = 6, p-value = 0.2237
```

Resultado test M de Box

El resultado del test fue no significativo ($\chi^2 = 8.20$, df = 6, p = 0.2237), lo que indica que no se rechaza la hipótesis nula de igualdad de las matrices de covarianzas. Los patrones de variabilidad y la relación entre las dos variables cuantitativas no difieren significativamente entre los grupos. Esto implica que las posibles diferencias en eficacia o efectos secundarios entre tratamientos no se deben a diferencias en la dispersión o estructura de covarianzas, sino a diferencias reales en las medias

1.7 Realizar un MANOVA de un factor, el tratamiento o factor group, y contrastar si hay diferencias entre ellos

MANOVA (análisis multivariante de la varianza) evalúa si el factor group tiene un efecto global y simultáneo sobre más de una variable dependiente (en este caso, efficacy y sideeffect). El código en R que utilizamos para realizarlo es el siguiente:

```
modelo_manova <- manova(cbind(efficacy, sideeffect) ~ group, data = sleep)
```

Para poder contrastar las diferencias utilizamos Wilk's Lambda, el cual nos indíca que cuanto más bajo el valor de Wilks, mayor evidencia de que hay diferencias entre los grupos.

Te da un p-valor:

Si $p < 0.05$ → rechazas la igualdad de medias multivariantes → hay diferencias entre grupos.

Si $p \geq 0.05$ → no hay evidencia suficiente de que existan diferencias globales.

```
          Df   Wilks approx F num Df den Df    Pr(>F)
group      2 0.38437   7.9686      4     52 4.349e-05 ***
Residuals 27
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Resultado test Manova

El test de Wilks Lambda es altamente significativo (0,384), indica que solo el 38,44% de la varianza no está explicada por este modelo. Además, observamos un p-valor muy por debajo de 0.05. Por ello, existen diferencias multivariantes estadísticamente significativas entre los grupos de tratamiento. Vemos entonces que el tratamiento tiene un efecto global sobre la combinación de las variables efficacy y sideefect

1.8 Como tenemos más factores podemos considerar un modelo general con todos los factores (sin interacciones) y el modelo más simple con solo el factor tratamiento y contrastar con la función anova() si el modelo simple explica la variación de los datos.

Para realizar este ejercicio, hemos construido dos modelos MANOVA para analizar conjuntamente las variables efficacy y sideeffect:

- Un modelo simple, que incluye únicamente el tratamiento (group) como factor explicativo.

```
manova(cbind(efficacy, sideeffect) ~ group, data = sleep)
```

- Un modelo completo, que incorpora además los factores gender y comorbidity, sin interacciones.

```
manova(cbind(efficacy, sideeffect) ~ group + gender + comorbidity, data = sleep)
```

Ambos modelos han sido comparados mediante la función anova(). El resultado no fue estadísticamente significativo (p = 0.4577), lo que indica que el modelo completo no mejora significativamente la explicación de la variabilidad multivariante respecto al modelo más simple.

En consecuencia, se concluye que el factor group es suficiente para explicar las diferencias multivariantes observadas en efficacy y sideeffect, y que la inclusión de gender y comorbidity no aporta una mejora significativa.

2. Ejercicio 2 (30 pt)

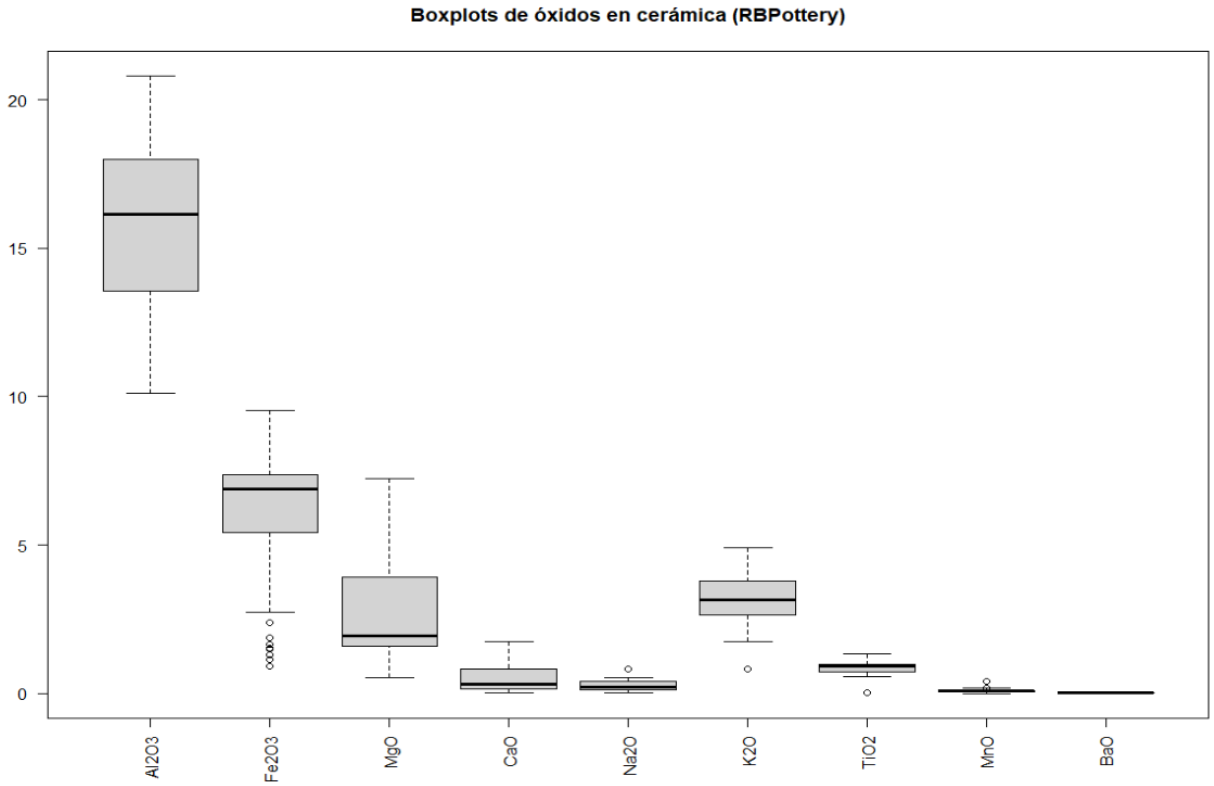
Tubb et al. (1980) publicaron los resultados de un análisis químico de 48 objetos de cerámica romano-británica. Los datos se hallan en el archivo RBpottery.RData. Los números son el porcentaje de metal oxidado determinado por la espectrometría por absorción atómica para nueve óxidos. Los lugares de los hornos estaban en tres regiones (1=Gloucester, 2=Llanedeyn, 3=Caldicot), (4=Islands Thorns, 5=Ashley Rails). Los datos se han escaneado de la tabla 2.2 de Baxter (2003, pág. 21) y se han preservado tres probables errores tipográficos de la publicación original. Si eliminamos esas tres observaciones dudosas, los 45 objetos restantes se pueden hallar en el **data frame HSAUR::pottery.**



2.1 Estudiar la estadística descriptiva univariante de los datos originales y seleccionar los posibles valores atípicos únicos (y extraños) para cada variable. Completar el estudio con un análisis de componentes principales con los porcentajes de metal oxidado, una vez sean estandarizados, para descubrir las tres observaciones que se alejan de los grupos de puntos que representan a las tres regiones.

En primer lugar, realizamos un estudio descriptivo univariante de los óxidos metálicos presentes en los 48 objetos de nuestra base de datos RBPottery. Vemos que las variables analizadas corresponden a los nueve óxidos metálicos.

Para poder detectar outliers, se calcularon estadísticas descriptivas y se representaron gráficamente mediante boxplots. Este análisis permitió detectar asimetrías y la presencia de valores atípicos (outliers) en varias variables, especialmente en Fe2O3, donde se observa una concentración importante de valores bajos fuera del rango intercuartílico. También se identificaron outliers aislados en otras variables como MnO, TiO2, Na2O y K2O



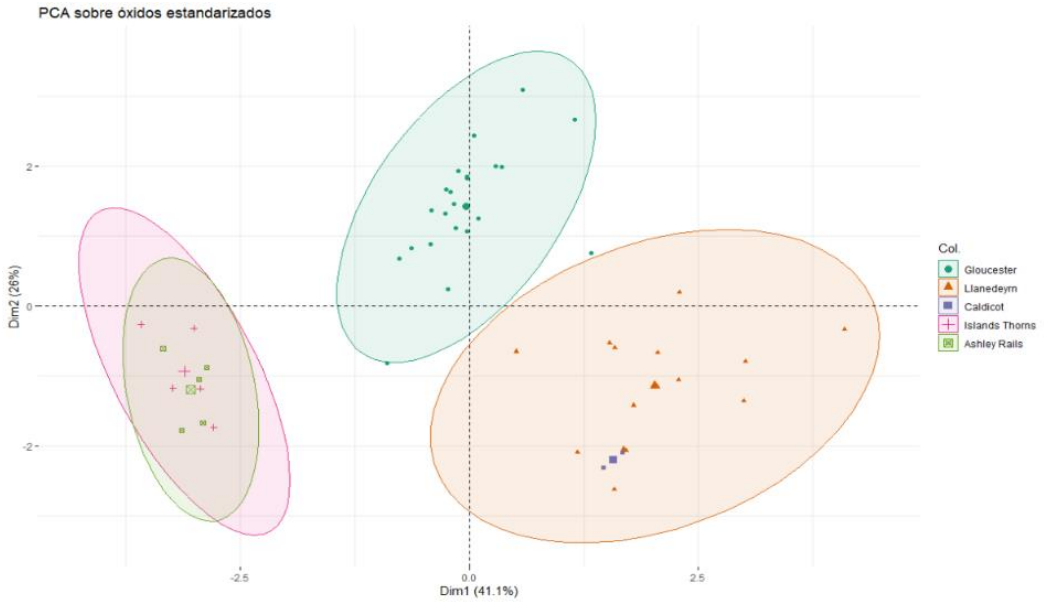
Resultado de boxplot de óxidos en Rstudio

Outliers detectados:

Fe2O3 → 39, 40, 41, 42, 43, 44, 45, 46, 48; Na2O → 17; K2O → 36; TiO2 → 4, 47; MnO → 35, 36

Para sistematizar esta detección, se aplicó el criterio de rango intercuartílico (IQR), considerándose atípicos aquellos valores fuera del rango [Q1 − 1.5·IQR, Q3 + 1.5 · IQR].

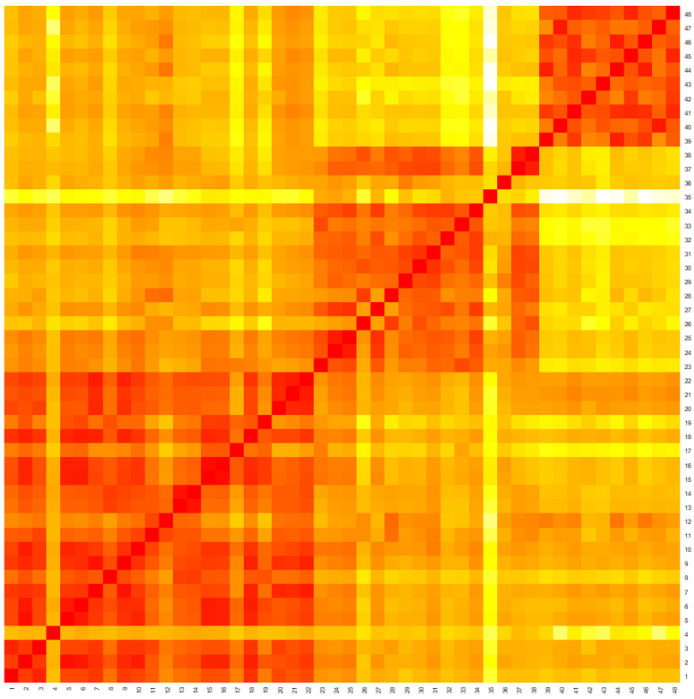
Posteriormente, aplicamos un análisis de componentes principales (PCA) sobre las nueve variables estandarizadas para identificar patrones multivariantes y detectar observaciones alejadas. En el gráfico del PCA, los objetos cerámicos se representaron según sus dos primeros componentes principales (que explican conjuntamente el 67.1% de la varianza), y se colorearon por región



Resultado de PCA de óxidos en Rstudio

Observamos algunas piezas visiblemente alejadas del centro de sus respectivos grupos, lo que refuerza la identificación previa de valores atípicos univariantes.

2.2 Calcular la distancia euclídea entre los objetos y representarla en un gráfico de calor (*heatmap*) sin dendogramas. Explicar brevemente el resultado.



Heatmap de distancias euclídeas entre objetos cerámicos

Las celdas de la matriz están coloreadas según la intensidad de la distancia:

- Rojo intenso: distancia muy baja (muestras muy similares).
- Amarillo claro o blanco: distancia alta (muestras muy distintas)

Se aprecia una banda roja intensa en la diagonal, como es de esperar, ya que la distancia de cada objeto consigo mismo es cero.

A lo largo de la matriz, se observan bloques rectangulares de tonos similares (rojo-anaranjado) agrupados alrededor de subconjuntos de observaciones. Estos bloques reflejan la existencia de subgrupos de piezas con composición química homogénea, probablemente coincidentes con las distintas regiones, como se observó también en el análisis PCA anterior.

Además, se pueden detectar algunas columnas o filas con valores más claros, lo que sugiere piezas que están químicamente más alejadas del resto (es decir, observaciones atípicas multivariantes). Esto refuerza la identificación previa de valores atípicos en Fe2O3, MnO y TiO2.

2.3 Representar los objetos en un gráfico en red con la función ggraph() del paquete ggraph. Para ello utilizaremos una similitud como por ejemplo 1/(1 + dist.eucl).

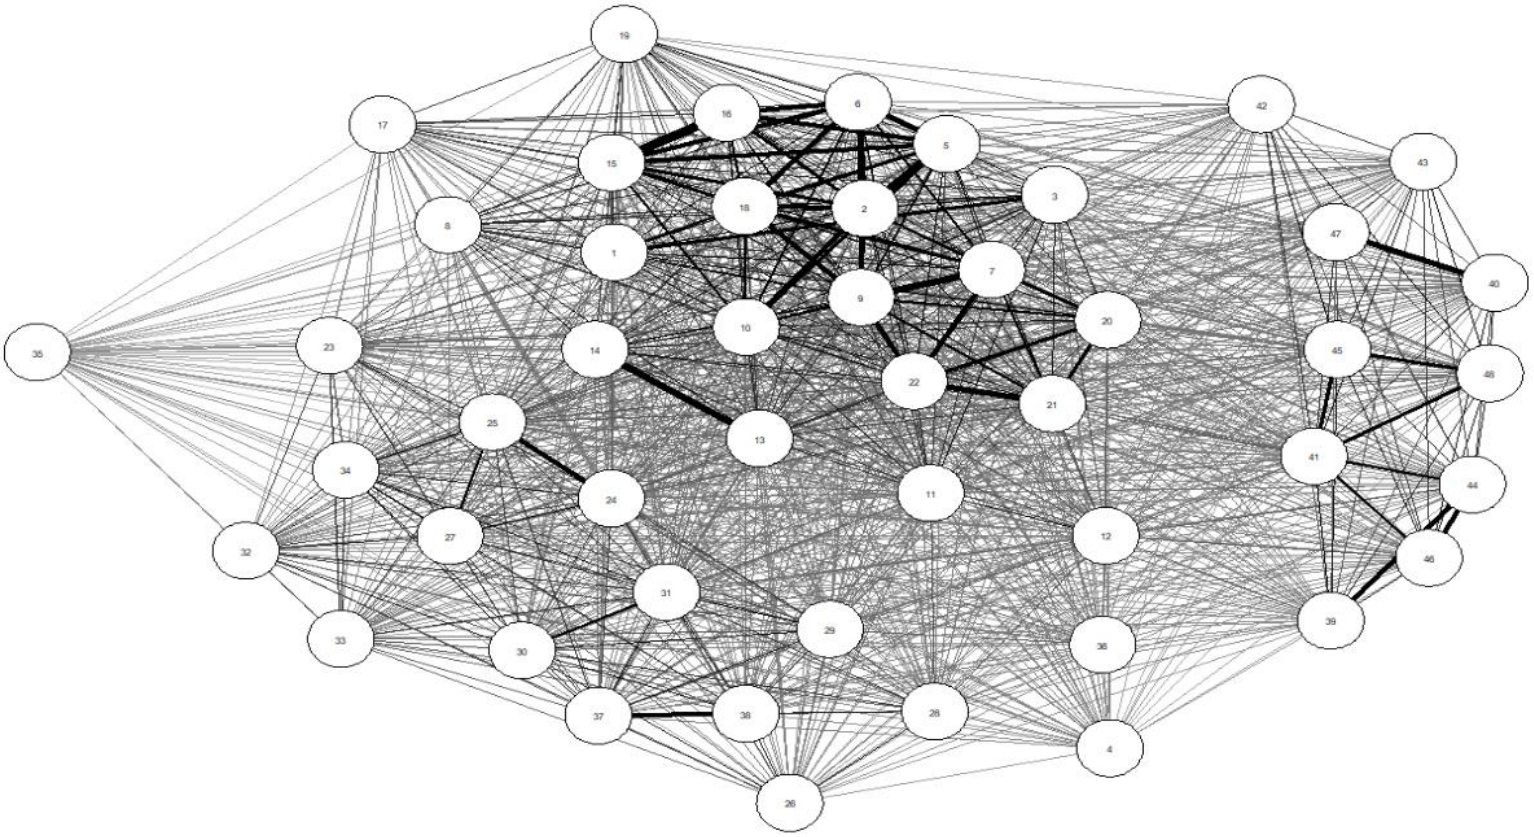
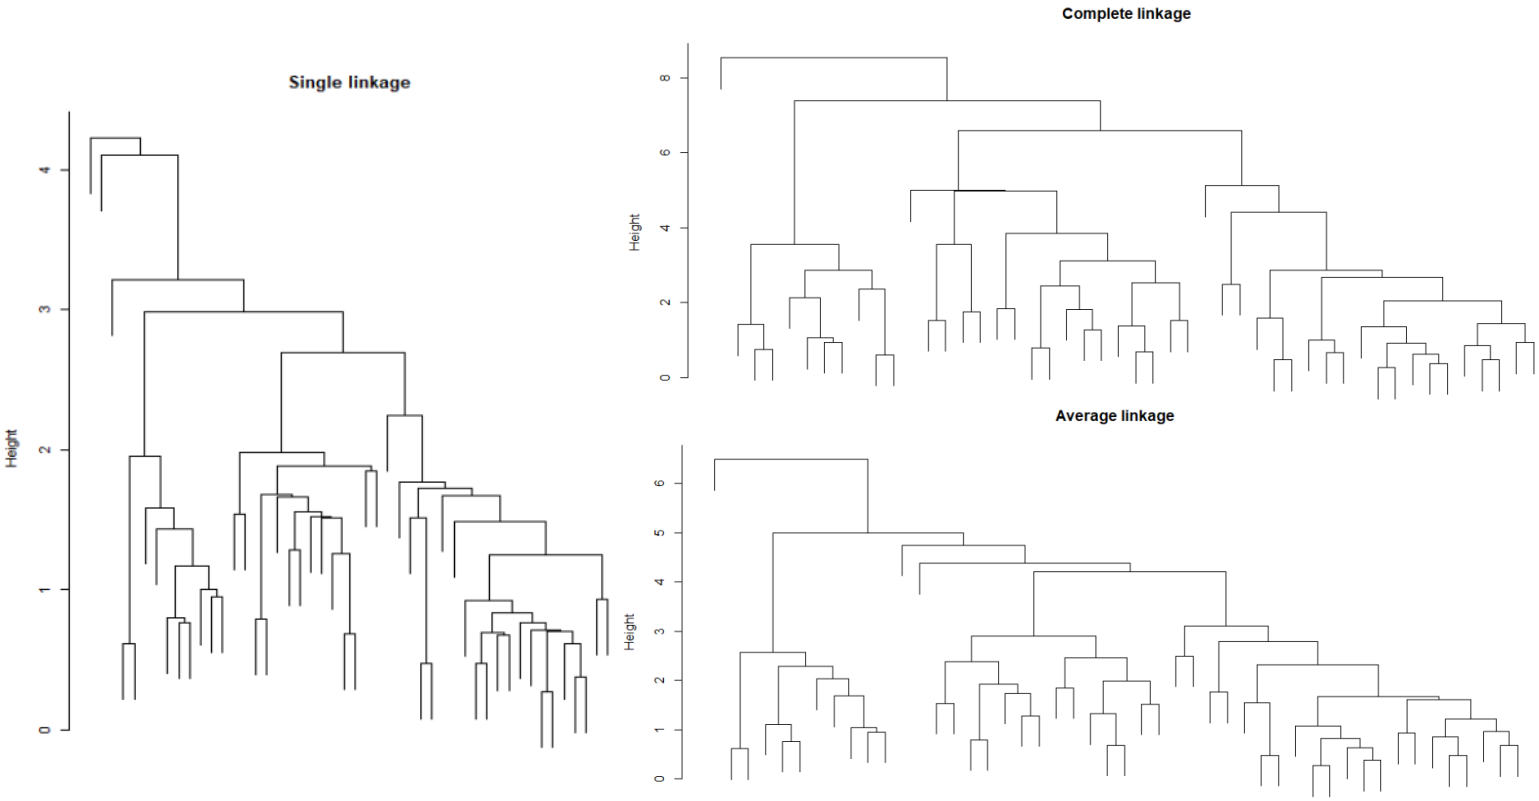


Gráfico en red (similitud = 1 / (1 + dist.eucl)

El resultado confirma visualmente la existencia de subgrupos de piezas estrechamente relacionadas químicamente, así como nodos periféricos con menor conexión, que podrían corresponder a observaciones atípicas o poco representativas

2.4 Realizar un análisis jerárquico aglomerativo con la distancia euclídea y los tres métodos de *linkage*: single, complete y average. Dibujar los dendogramas con las tres uniones. ¿Cuál es el método de *linkage* que proporciona el mejor resultado para clasificar los objetos y sus hornos en las tres regiones propuestas?



Resultado análisis jerárquico aglomerativo

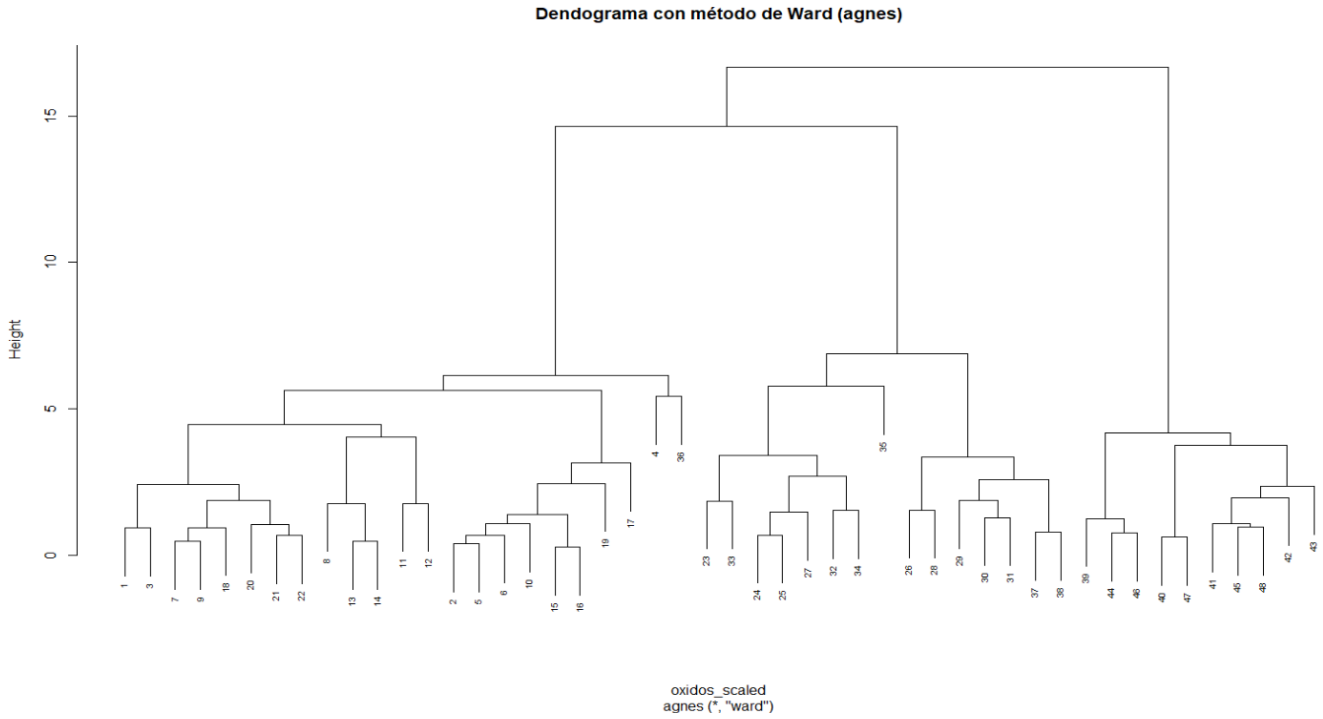
Representamos los dendogramas para cada uno de los métodos. Se observa que:

- El método *single linkage* presenta un efecto de encadenamiento, donde muchos objetos se agrupan secuencialmente formando ramas alargadas, lo que dificulta la identificación de grupos compactos.
- El *complete linkage* produce clústeres más compactos y bien separados, aunque con algunos agrupamientos que no se corresponden claramente con las tres regiones geográficas de los hornos.

- El método *average linkage* genera un dendograma equilibrado, con una estructura clara de tres agrupamientos principales bien diferenciados, lo que se alinea mejor con la estructura regional observada previamente (por ejemplo, en el PCA).

Por tanto, concluimos que el método average es el más adecuado para este conjunto de datos, ya que proporciona el resultado más consistente con las tres regiones de origen propuestas para clasificar los objetos cerámicos

2.5 Repetir el apartado anterior con el método de Ward y un total de 3 conglomerados que podemos implementar con la función agnes() del paquete cluster.



Resultado método Ward con función agnes()

El dendograma obtenido refleja una estructura jerárquica clara. Además del gráfico, hemos realizado un corte en tres conglomerados, que es el número de grupos esperado según la distribución geográfica de las piezas en tres regiones principales de hornos.

La partición resultante generó grupos de tamaño desigual:

- Grupo 1: 23 piezas
- Grupo 2: 15 piezas
- Grupo 3: 10 piezas

Esta distribución sugiere que las composiciones químicas permiten una separación clara pero asimétrica entre las regiones. Visualmente, el dendograma muestra que el método de Ward forma clústeres más compactos y homogéneos que los métodos de linkage utilizados anteriormente.

2.6 Aplicar el procedimiento de particionado de las *k*-medias con el algoritmo de Hartigan-Wong para 3 grupos (regiones) y 5 grupos (hornos). Fijaremos una semilla de 1234.

Para 3 grupos, dibujar los lugares como puntos de un PCA o CA con un símbolo distinto para cada grupo[2]. Hallar los centros de cada grupo y dibujarlos en el gráfico anterior. Hallar las sumas de cuadrados dentro de cada grupo y los tamaños de los conglomerados.

2.7 Realizar un particionado alrededor de los medoides o *k*-medoides o PAM con la función pam() del paquete cluster de R y hallar los medoides.

Calcular y representar la silueta como medida de la calidad de los conglomerados formados.

Identificar los tres medoides representativos de las tres regiones.

Estudiar con las siluetas el mejor número de conglomerados.

3. Ejercicio 3 (30 pt)

Con los mismos 45 objetos de cerámica del ejercicio anterior, se pretende obtener una regla de clasificación que identifique la región de los objetos a partir de sus oxidaciones.

3.1 Realizar un gráfico con la función pairs() de las variables con distintos símbolos o colores para cada región.

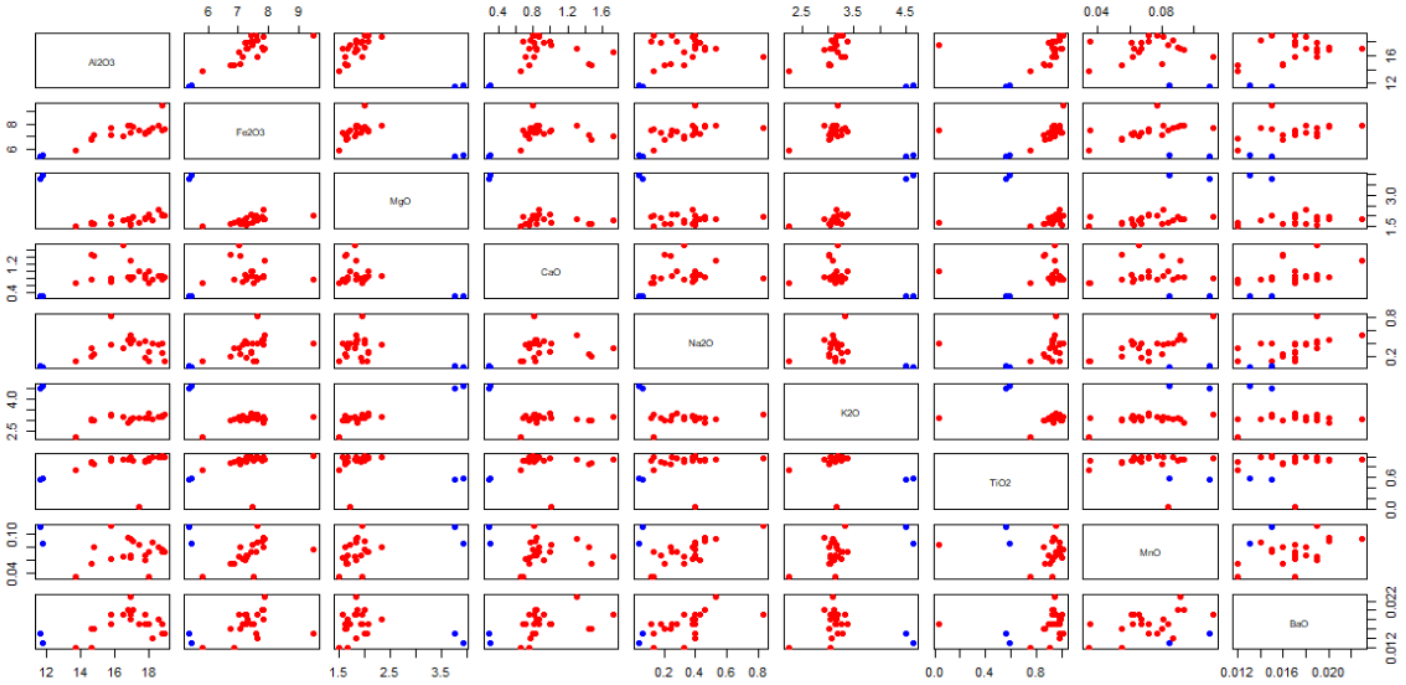


Gráfico de dispersión de óxidos por regiones (Kiln)

Este gráfico de matrices de dispersión facilita la identificación visual de patrones entre combinaciones de óxidos y cómo se agrupan según la región. Se aprecia cierta separación entre las regiones, especialmente en pares como Fe2O3 vs Al2O3, o K2O vs Na2O, lo que sugiere un potencial para su uso en clasificación discriminante.

3.2 Contrastar la homogeneidad de las matrices de varianzas-covarianzas de las tres regiones con el test de Bartlett. ¿Está justificado hacer un análisis lineal discriminante?

Para determinar si es apropiado utilizar un análisis discriminante lineal, es necesario comprobar la homogeneidad de las matrices de varianzas-covarianzas entre grupos.

Se aplicó el test M de Box a las tres regiones principales (Gloucester, Llanedeyn, Caldicot) mediante la función boxM() del paquete biotools. El resultado en R fue el siguiente:

```
data:  RBPottery_3[, 4:12]
Chi-Sq (approx.) = -752.56, df = 45,
p-value = 1
```

Resultado BoxM

El estadístico negativo y el valor-p igual a 1 indican que el test no es válido en estas condiciones, probablemente por un tamaño muestral insuficiente respecto al número de variables.

3.3 Realizar un análisis discriminante lineal con la función lda() del paquete MASS y probabilidades a priori iguales a 1/3.

Se realizó un análisis discriminante lineal con la función lda() del paquete MASS, utilizando como predictores los óxidos (Al2O3, Fe2O3, MgO, CaO, Na2O, K2O, TiO2, MnO, BaO) y como variable de agrupación la región Kiln.

El conjunto de datos fue filtrado para contener únicamente las tres regiones principales y se eliminaron los niveles no utilizados

El modelo resultante proporciona funciones discriminantes lineales que permiten clasificar nuevos objetos según sus composiciones químicas

- Las probabilidades a priori de cada grupo (en este caso, iguales).
- Las medias por grupo para cada variable predictora.
- Los coeficientes de la función discriminante, que indican la contribución de cada óxido a la discriminación entre grupos.

```
Call:
lda(x[, -10], grouping = x[, 10], prior = prior_equilibrado)

Prior probabilities of groups:
Gloucester   Caldicot
       0.5        0.5

Group means:
                Al2O3    Fe2O3      MgO       CaO
Gloucester 16.94091 7.430909 1.836364 0.9422727
Caldicot   11.70000 5.415000 3.855000 0.2950000
                Na2O      K2O       TiO2
Gloucester 0.3481818 3.105455 0.8963636
Caldicot   0.0500000 4.575000 0.5750000
                MnO         BaO
Gloucester 0.07172727 0.01713636
Caldicot   0.09750000 0.01400000

Coefficients of linear discriminants:
              LD1
Al2O3  -1.17790911
Fe2O3   0.01980734
MgO     5.83346483
CaO    -2.36186542
Na2O   -5.22040898
K2O     3.41232423
TiO2   -1.60261625
MnO    12.83087419
BaO   167.11976641
```

Resultado Box

En este caso, por ejemplo, el modelo sugiere que BaO, MnO, MgO y Na2O son especialmente relevantes para distinguir entre regiones.

3.4 Hallar las probabilidades a posteriori.

Se utilizó la función predict() sobre el modelo lda_modelo para obtener las probabilidades a posteriori de pertenencia de cada objeto a las tres regiones. Estas probabilidades permiten analizar qué objetos presentan mayor incertidumbre en su clasificación y cuáles están claramente asociados a una región específica.

La salida del análisis muestra que muchas observaciones presentan probabilidades a posteriori extremadamente cercanas a 1 para una de las regiones (por ejemplo, Gloucester), mientras que las probabilidades para las demás regiones son prácticamente nulas (del orden de 10^{-165} o menores). Esto indica que el modelo tiene una alta capacidad discriminativa, es decir, clasifica con mucha seguridad a los objetos según su composición de óxidos.

```
[1] Gloucester Gloucester Gloucester Gloucester
[5] Gloucester Gloucester
Levels: Gloucester Caldicot
  Gloucester      Caldicot
1          1 1.308216e-165
2          1 1.969967e-166
3          1 2.182000e-174
4          1 2.973939e-151
5          1 3.831275e-169
6          1 1.171657e-165
```

Este resultado refuerza la idea de que existen diferencias sistemáticas y marcadas en los porcentajes de óxidos entre las regiones, lo que justifica el uso del análisis discriminante lineal para este tipo de clasificación. Sin embargo, si aparecieran casos con probabilidades repartidas entre varias regiones, se debería considerar una posible superposición o similitud composicional entre grupos

3.5 Predecir la región del objeto 4 de la base de datos original completa (la de 48 objetos).

Para predecir la región de procedencia del objeto número 4 en la base de datos original de 48 objetos, se ha utilizado el modelo LDA previamente ajustado con las 45 observaciones correspondientes a las tres regiones principales.

```
objeto_4 <- RBPottery[4, 4:12, drop = FALSE]

prediccion <- predict(lda_modelo, objeto_4)

prediccion$class

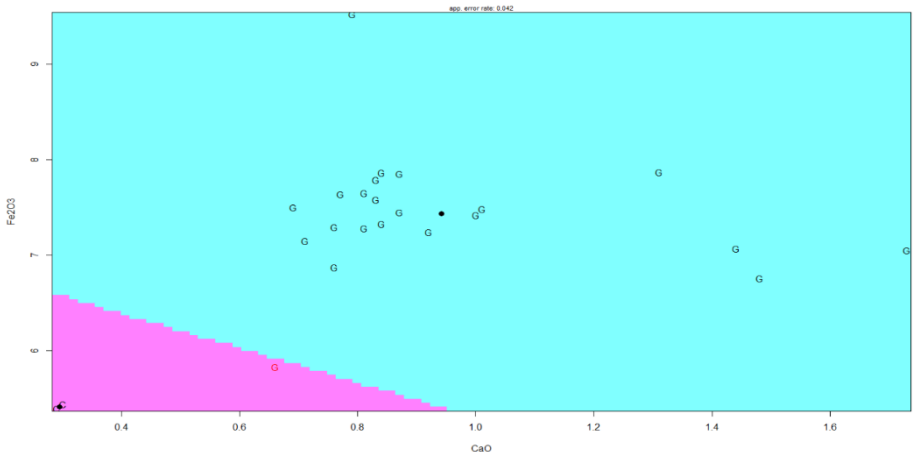
prediccion$posterior
```

El modelo predice que el objeto 4 pertenece a la región Gloucester, con una probabilidad a posteriori de 1, frente a una probabilidad prácticamente nula para el resto de regiones.

Este resultado muestra que el modelo clasifica al objeto 4 con certeza absoluta, basándose en los perfiles de oxidación química.

3.6 Utilizar la función partimat() del paquete klaR para mostrar los resultados de la clasificación lineal y cuadrática.

La función partimat() permite representar los límites de decisión generados por un modelo de clasificación, ya sea LDA (análisis discriminante lineal) o QDA (análisis discriminante cuadrático). Es útil para visualizar cómo los grupos (en este caso, regiones) son separados en función de las variables predictoras.

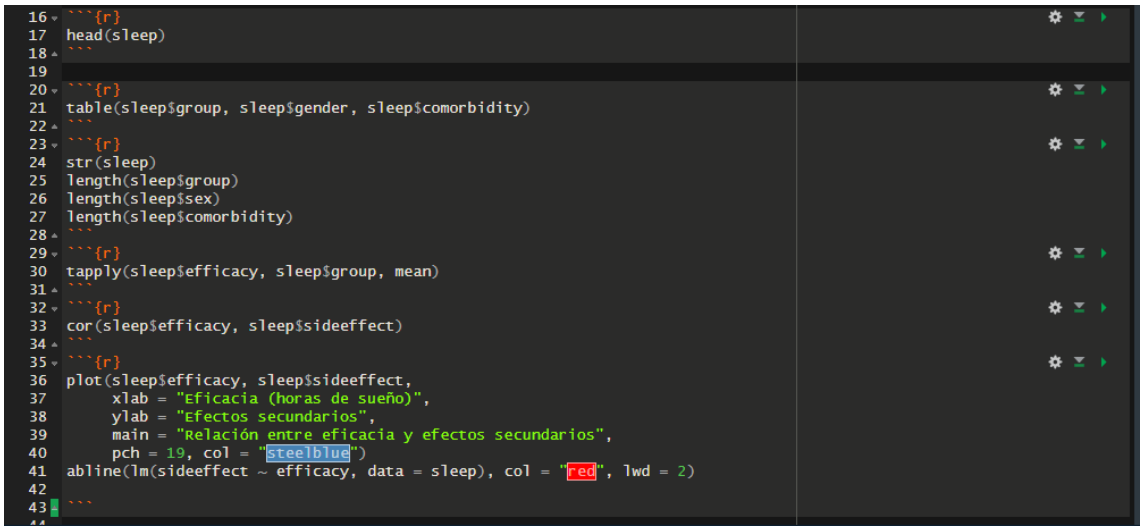


Output LDA

La mayoría de las muestras se encuentran en la zona azul, correctamente clasificadas como Gloucester, lo que indica que estas dos variables permiten una buena discriminación para esta región.

ANEXO – CÓDIGO EN R

########################## CÓDIGO EJERCICIO 1.1 ##################################

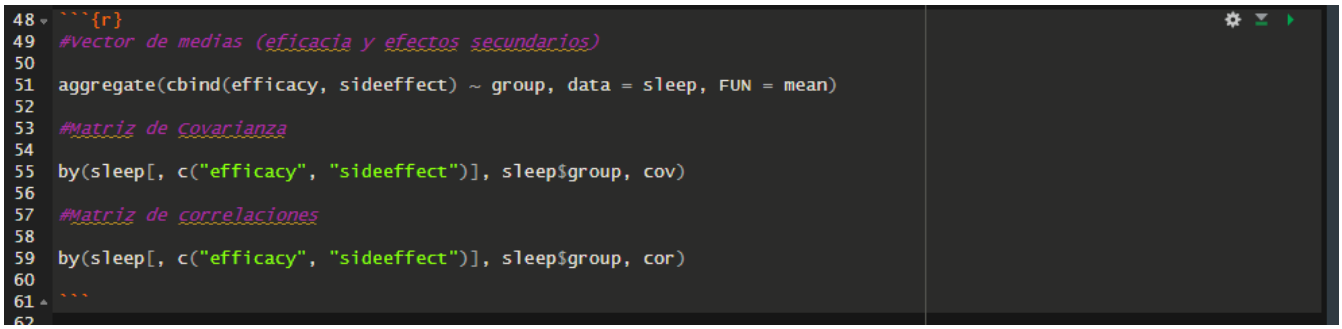


```r
```{r}
head(sleep)
```

```{r}
table(sleep$group, sleep$gender, sleep$comorbidity)
```
```{r}
str(sleep)
length(sleep$group)
length(sleep$sex)
length(sleep$comorbidity)
```
```{r}
tapply(sleep$efficacy, sleep$group, mean)
```
```{r}
cor(sleep$efficacy, sleep$sideeffect)
```
```{r}
plot(sleep$efficacy, sleep$sideeffect,
     xlab = "Eficacia (horas de sueño)",
     ylab = "Efectos secundarios",
     main = "Relación entre eficacia y efectos secundarios",
     pch = 19, col = "steelblue")
abline(lm(sideeffect ~ efficacy, data = sleep), col = "red", lwd = 2)

```
```

########################## CÓDIGO EJERCICIO 1.2 ##################################



```r
```{r}
#Vector de medias (eficacia y efectos secundarios)

aggregate(cbind(efficacy, sideeffect) ~ group, data = sleep, FUN = mean)

#Matriz de covarianza

by(sleep[, c("efficacy", "sideeffect")], sleep$group, cov)

#Matriz de correlaciones

by(sleep[, c("efficacy", "sideeffect")], sleep$group, cor)

```
```



```r
```{r}
calcular_indices <- function(df) {
  datos <- df[, c("efficacy", "sideeffect")]

  cov_matrix <- cov(datos)
  cor_matrix <- cor(datos)

  var_gen <- det(cov_matrix)
  var_total <- sum(diag(cov_matrix))
  eta2 <- 1 - det(cor_matrix)

  return(list(
    varianza_generalizada = var_gen,
    varianza_total = var_total,
    eta2 = eta2
  ))
}
res_treat0 <- calcular_indices(subset(sleep, group == "treat0"))
res_treat1 <- calcular_indices(subset(sleep, group == "treat1"))
res_treat2 <- calcular_indices(subset(sleep, group == "treat2"))

res_treat0
res_treat1
res_treat2

```
```

########################## CÓDIGO EJERCICIO 1.3 ##################################

```r
```{r}

datos <- sleep[, c("efficacy", "sideeffect")]

grupos <- unique(sleep$group)

# Creamos función para test de Mardia manual
mardia_manual <- function(data) {
  n <- nrow(data)
  p <- ncol(data)
  S <- cov(data)
  xbar <- colMeans(data)

  # Distancias de Mahalanobis
  dif <- sweep(data, 2, xbar)
  Sinv <- solve(S)
  D <- as.matrix(dif) %*% Sinv %*% t(as.matrix(dif))

  b1p <- sum(D^3) / n^2
  b2p <- sum(diag(D)^2) / n

  gamma1p <- n * b1p / 6
  f <- p * (p + 1) * (p + 2) / 6
  pval_gamma1p <- pchisq(gamma1p, df = f, lower.tail = FALSE)

  gamma2p <- (b2p - p * (p + 2)) / sqrt((8 * p * (p + 2)) / n)
  pval_gamma2p <- 2 * (1 - pnorm(abs(gamma2p)))

  list(
    b1p = b1p,
    b2p = b2p,
    gamma1p = gamma1p,
    pval_gamma1p = pval_gamma1p,
    gamma2p = gamma2p,
    pval_gamma2p = pval_gamma2p
  )
}

# test para cada grupo
resultados <- lapply(grupos, function(g) {
  cat("\nGrupo:", g, "\n")
  datos_g <- subset(sleep, group == g)[, c("efficacy", "sideeffect")]
  print(mardia_manual(datos_g))
})
```

```r
#Gráfico qq-plot

vars <- c("efficacy", "sideeffect")
grupos <- unique(sleep$group)
par(mfrow = c(1, 3))  # una fila, tres columnas
for (g in grupos) {
  datos_g <- subset(sleep, group == g)[, vars]
  S <- cov(datos_g)
  xbar <- colMeans(datos_g)

  # Distancias de Mahalanobis
  D2 <- mahalanobis(datos_g, center = xbar, cov = S)

  # QQ-plot frente a distribución chi-cuadrado con 2 grados de libertad
  qqplot(
    qchisq(ppoints(length(D2)), df = 2),  # cuantiles teóricos
    sort(D2),   # distancias reales
    main = paste("QQ Mahalanobis - Grupo", g),
    xlab = "Cuantiles teóricos Chi² (df=2)",
    ylab = "Distancias de Mahalanobis"
  )
  abline(0, 1, col = "red", lty = 2)
}


```
```

########################## CÓDIGO EJERCICIO 1.4 ##################################

```r
```{r}

# Cargamos el paquete
library(MVN)

# Aplicamos la función mardia() del paquete MVN

for (grupo_actual in unique(sleep$group)) {
  cat("\n===== Grupo:", grupo_actual, "=====\n")

  datos_grupo <- subset(sleep, group == grupo_actual)[, c("efficacy", "sideeffect")]

  resultado_mardia <- mardia(data = datos_grupo)
  print(resultado_mardia)
}

```
```

########################## CÓDIGO EJERCICIO 1.5 ##################################

```r
```{r}
library(psych)

# Aplicar la función mardia() del paquete psych por grupo
for (grupo_actual in unique(sleep$group)) {
  cat("\n===== Grupo:", grupo_actual, "=====\n")

  datos_grupo <- subset(sleep, group == grupo_actual)[, c("efficacy", "sideeffect")]
  print(mardia(datos_grupo))
}
```
```

########################## CÓDIGO EJERCICIO 1.6 ##################################

```r
```{r}

library(heplots)

# Aplicamos test M de Box
boxM_resultado <- boxM(sleep[, c("efficacy", "sideeffect")], sleep$group)

print(boxM_resultado)

```
```

########################## CÓDIGO EJERCICIO 1.7 ##################################

```r

```{r}
# Modelo MANOVA
modelo_manova <- manova(cbind(efficacy, sideeffect) ~ group, data = sleep)

# Resumen multivariante (test de Wilks, Pillai, etc.)
summary(modelo_manova, test = "Wilks")
```
```

########################## CÓDIGO EJERCICIO 1.8 ##################################

```r
modelo_simple <- manova(cbind(efficacy, sideeffect) ~ group, data = sleep)
```

```r
modelo_completo <- manova(cbind(efficacy, sideeffect) ~ group + gender + comorbidity, data = sleep)
```

```r
anova(modelo_simple, modelo_completo)
```

########################## CÓDIGO EJERCICIO 2.1 ##################################

```r
oxidos <- RBPottery[, 4:12]

# Ver estadística descriptiva
summary(oxidos)

# Vamos a detectar outliers usando criterio IQR
outliers <- lapply(names(oxidos), function(col) {
  Q1 <- quantile(oxidos[[col]], 0.25)
  Q3 <- quantile(oxidos[[col]], 0.75)
  IQR <- Q3 - Q1
  limites <- c(Q1 - 1.5 * IQR, Q3 + 1.5 * IQR)
  which(oxidos[[col]] < limites[1] | oxidos[[col]] > limites[2])
})
names(outliers) <- names(oxidos)
outliers


# Usamos directamente la columna ID del dataset
outliers_ids <- lapply(names(outliers), function(var) {
  RBPottery$ID[outliers[[var]]]
})
names(outliers_ids) <- names(oxidos)
outliers_ids

# Boxplots
boxplot(oxidos,
        main = "Boxplots de óxidos en cerámica (RBPottery)",
        las = 2,
        col = "lightgray")
```

```r

library(factoextra)
library(ggplot2)

# Seleccionamos solo las columnas numéricas de óxidos (de Al2O3 a BaO)
oxidos <- RBPottery[, 4:12]  # columnas numéricas

# PCA estandarizado
pca_result <- prcomp(oxidos, scale. = TRUE)

# Visualizar individuos con colores por horno (Kiln)
fviz_pca_ind(pca_result,
             geom.ind = "point",
             col.ind = RBPottery$Kiln,
             palette = "Dark2",
             addEllipses = TRUE,
             ellipse.level = 0.95,
             repel = TRUE,
             title = "PCA sobre óxidos estandarizados")

```

########################## CÓDIGO EJERCICIO 2.2 ###################################

```r
# Seleccionamos y estandarizamos (paso anterior ya hecho) los óxidos
oxidos_scaled <- scale(oxidos)

# Calculamos la distancia euclídea entre observaciones
distancias <- dist(oxidos_scaled, method = "euclidean")
matriz_dist <- as.matrix(distancias)

# Asignamos nombres
rownames(matriz_dist) <- RBPottery$ID
colnames(matriz_dist) <- RBPottery$ID

# Generamos heatmap sin dendograma
png("heatmap_rbpottery.png", width = 1000, height = 1000)
heatmap(matriz_dist,
        Rowv = NA, Colv = NA,
        scale = "none",
        col = heat.colors(256),
        margins = c(6, 6),
        main = "Heatmap de distancias euclídeas entre objetos cerámicos")
dev.off()


```

########################## CÓDIGO EJERCICIO 2.3 ##################################

```r
library(qgraph)

#  Convertimos a matriz de similitud: sim_ij = 1 / (1 + dist_ij)
similitud <- 1 / (1 + matriz_dist)

# Representamos el gráfico en red con qgraph()
qgraph(similitud,
       layout = "spring",
       labels = RBPottery$ID,
       edge.color = "black",
       vsize = 4,
       label.scale.equal = TRUE,
       title = "Gráfico en red (similitud = 1 / (1 + dist.eucl))")
```

########################## CÓDIGO EJERCICIO 2.4 ##################################

```r
# Métodos de linkage
hc_single <- hclust(distancias, method = "single")
hc_complete <- hclust(distancias, method = "complete")
hc_average <- hclust(distancias, method = "average")

# Representamos los tres dendogramas
par(mfrow = c(1, 3))  # 1 fila, 3 columnas
plot(hc_single, main = "Single linkage", xlab = "", sub = "", labels = FALSE)
```

```r
plot(hc_complete, main = "Complete linkage", xlab = "", sub = "", labels = FALSE)
```

```r
plot(hc_average, main = "Average linkage", xlab = "", sub = "", labels = FALSE)
par(mfrow = c(1, 1))  # Restaurar
```

########################## CÓDIGO EJERCICIO 2.5 ##################################

```r
```{r}
library("cluster")

# Método Ward
agnes_ward <- agnes(oxidos_scaled, method = "ward")

# Dendograma
pltree(agnes_ward, main = "Dendograma con método de Ward (agnes)", cex = 0.6)

# Cortamos el árbol en 3 grupos
grupos_ward <- cutree(as.hclust(agnes_ward), k = 3)

# Distribución de grupos
table(grupos_ward)
```
```

########################## CÓDIGO EJERCICIO 3.1 ##################################

```r
```{r}
# Seleccionamos solo los objetos con regiones principales
regiones_principales <- c("Gloucester", "Llanedeyn", "Caldicot")
RBPottery_3 <- subset(RBPottery, Kiln %in% regiones_principales)
RBPottery_3$Kiln <- droplevels(RBPottery_3$Kiln)

# Asignamos colores a cada región
colores <- c("red", "blue", "orange")[RBPottery_3$Kiln]

# Gráfico de dispersión
pairs(RBPottery_3[, 4:12],
      col = colores,
      pch = 19,
      main = "Gráfico de dispersión de óxidos por regiones (Kiln)")

```
```

########################## CÓDIGO EJERCICIO 3.2 ##################################

```r
483 ########################## CÓDIGO EJERCICIO 3.2 ##################################
484
485 ```{r}
486 library(biotools)
487
488 # Selección de las tres regiones principales
489 regiones_principales <- c("Gloucester", "Llanedeyn", "Caldicot")
490 RBPottery_3 <- subset(RBPottery, Kiln %in% regiones_principales)
491 RBPottery_3$Kiln <- droplevels(RBPottery_3$Kiln)
492
493 # Aplicación del test M de Box
494 resultado_boxM <- boxM(RBPottery_3[, 4:12], RBPottery_3$Kiln)
495 print(resultado_boxM)
496
497 ```
```

########################## CÓDIGO EJERCICIO 3.2 ##################################

```r
library(biotools)

# Selección de las tres regiones principales
regiones_principales <- c("Gloucester", "Llanedeyn", "Caldicot")
RBPottery_3 <- subset(RBPottery, Kiln %in% regiones_principales)
RBPottery_3$Kiln <- droplevels(RBPottery_3$Kiln)

# Aplicación del test M de Box
resultado_boxM <- boxM(RBPottery_3[, 4:12], RBPottery_3$Kiln)
print(resultado_boxM)
```

########################## CÓDIGO EJERCICIO 3.3 ##################################

```r
library(MASS)

regiones_principales <- c("Gloucester", "Llanedeyn", "Caldicot")
RBPottery_3 <- droplevels(subset(RBPottery, Kiln %in% regiones_principales))


x <- RBPottery_3[, c(4:12, 3)]

# Establecemos probabilidades a priori iguales
niveles <- nlevels(x[, 10])
prior_equilibrado <- rep(1 / niveles, niveles)

# Aplicación del análisis discriminante lineal (LDA)
lda_modelo <- lda(x[, -10], grouping = x[, 10], prior = prior_equilibrado)

# Mostrar el resultado
print(lda_modelo)
```

########################## CÓDIGO EJERCICIO 3.4 ##################################

```r
# Predicción de clases y probabilidades a posteriori
prediccion <- predict(lda_modelo)

# Mostramos las clases predichas y las probabilidades
head(prediccion$class)
head(prediccion$posterior)
```

########################## CÓDIGO EJERCICIO 3.5 ##################################

```r
objeto_4 <- RBPottery[4, 4:12, drop = FALSE]
prediccion <- predict(lda_modelo, objeto_4)

prediccion$class
prediccion$posterior
```

########################## CÓDIGO EJERCICIO 3.6 ##################################

```r
library(klaR)

# usamos las 45 observaciones válidas
RBPottery_3 <- droplevels(subset(RBPottery, Kiln %in% c("Gloucester", "Llanedeyn", "Caldicot")))

# seleccionamos las variables predictoras y la clase
X <- RBPottery_3[, 4:12]      # Variables predictoras
Y <- RBPottery_3$Kiln         # Factor región

# visualización con clasificación lineal (LDA)
partimat(Kiln ~ Fe2O3 + CaO, data = RBPottery_3, method = "lda", main = "Clasificación LDA")

# visualización con clasificación cuadrática (QDA)
table(RBPottery_3$Kiln)

```