PEC 1 Análisis Multivariante, Alberto Torrejón Aquino

```
load("C:/Users/Balerto/Desktop/virus.rda")
```

Ejercicio 1

Apartado a) Los datos son recuentos de 0 a 32. Calcular los totales por virus que llamaremos total_residue. Dar el recorrido de esta variable.

```
total_residue <- rowSums(virus[, 1:18])
range(total_residue)
```

```
## [1] 122 231
```

En este caso, calculamos el total de de residuos y lo introducimos dentro de una variable (total_residue) y con la función range le pedimos que nos muestre el valor mínimo y máximo de este conjunto. Con ello, sabemos que el recorrido de esta variable abarca desde 122 como valor más pequeño hasta 231 como valor más grande.

Apartado b) Calcular las medias para cada proteína

```
medias <- colMeans(virus[, 1:18])

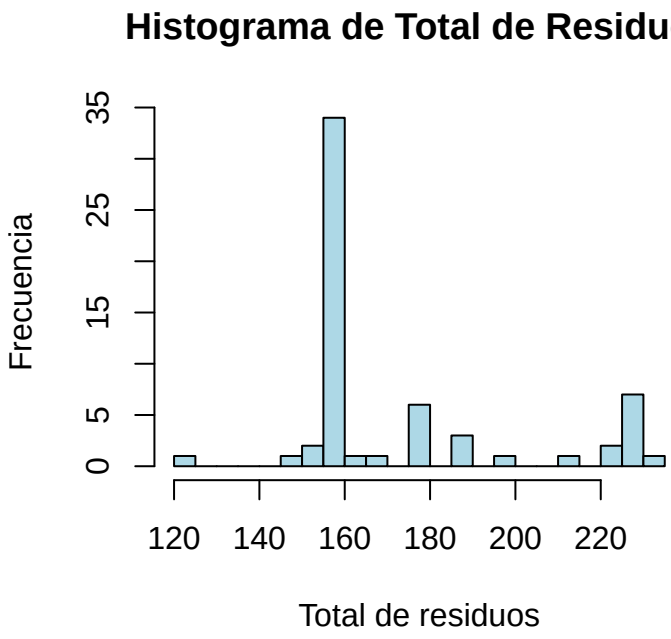
medias
```

```
##         V1         V2         V3         V4         V5         V6         V7
## 20.3114754 13.6721311 15.4098361 17.8032787  9.4098361  9.9672131 17.1639344
##         V8         V9        V10        V11        V12        V13        V14
##  0.8688525 12.4754098  1.3934426  7.4918033 14.1147541  5.5901639  7.7377049
##        V15        V16        V17        V18
##  1.4754098  4.9344262 11.2622951  2.5573770
```

Calculamos las medias de cada una de las columnas para tener las medias de cada uno de los aminoácidos en las 18 mediciones realizadas.

Apartado c) Dibujar el histograma de la figura 3. Para ello habrá que fijar las marcas de clase en algunos valores como 120, . . . , 160, . . . , 180, . . . y además un ancho de barra de 5. Cualquier otra configuración distorsiona el histograma que resulta un gráfico poco robusto.

```
hist(
  total_residue,
  breaks = seq(120, max(total_residue)+5, by = 5),  # Creamos secuencia desde 120 y sube de 5 en 5
  main = "Histograma de Total de Residuos",
  xlab = "Total de residuos",
  ylab = "Frecuencia",
  col = "lightblue",
)
```



Como podemos observar en el histograma, la mayoría de los virus se concentran los residuos principalmente en un intervalo entre [150,170), aunque también observamos algunos valores superiores a 220 que son reseñables, ya que generan valores atípicos de residuos.

Apartado d) Dibujar el diagrama de cajas (boxplot) de la figura 3. Identificar el valor atípico más destacado del grupo de los Furoviruses

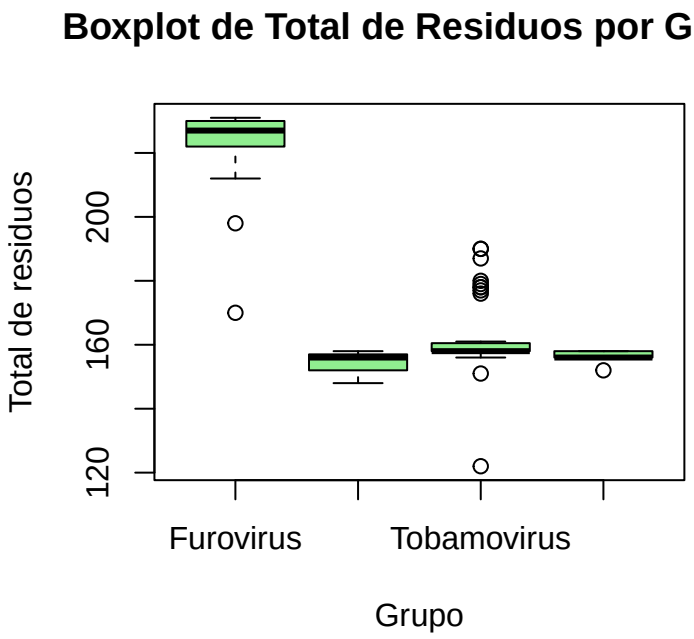
En este caso, tenemos que clasificar nuestro dataframe en los grupos víricos para poder realizar el boxplot de la figura 3, por lo que, vamos a definir nuestro vector de la siguiente forma:

```
grupo <- c(
  rep("Tobamovirus", 39),
  rep("Tobravirus", 6),
  rep("Hordeivirus", 3),
  rep("Furovirus", 13)
)
```

Le decimos que nuestro vector sea de 61 elementos (39+6+3+13) y que, en este, se repitan los nombres de los grupos más destacados de los Virus.

Ya con nuestros grupos víricos definidos, podemos representar nuestro boxplot utilizando este vector

```
boxplot(
  total_residue ~ grupo,
  main = "Boxplot de Total de Residuos por Grupo",
  xlab = "Grupo",
  ylab = "Total de residuos",
  col = "lightgreen",
)
```



Al representar nuestro boxplot, podemos observar que los Furovirus tienen tienen valores de nuestra variable total_residue más altos. Este grupo es el que tenía los valores atípicos, mientras que si hacemos la comparativa con Tobamovirus, Trobavirus y Hordeivirus tienen valores más homogéneos, concentrados entre 150-170

Apartado e) Dividir la variable total_residue en una partición de cuatro intervalos de forma que podamos clasificar los tipos de virus perfectamente, excepto un único virus extraño.

Lo primero que tenemos que ver son los rangos de cada uno de los virus. Esto, lo podemos conseguir con la función tapply, agrupando los datos en función de categoría y rango

```
tapply(total_residue, grupo, range)
```

```
## $Furovirus
## [1] 170 231
##
## $Hordeivirus
## [1] 148 158
##
## $Tobamovirus
## [1] 122 190
##
## $Tobravirus
## [1] 152 158
```

Como se puede observar, Tobamovirus, al alcanzar valores de hasta 190, entra en el rango de Furovirus.

Además, Hordeivirus y Tobravirus presentan rangos que se solapan entre sí.
Por ello, es de esperar que uno de los virus mal clasificados pertenezca a los Tobamoviruses.

A partir de esta observación, vamos a realizar la siguiente partición de intervalos:

- Intervalo 1: [120, 148) → Virus de residuos bajos → Tobamovirus
- Intervalo 2: [148, 160) → Hordeivirus y Tobravirus
- Intervalo 3: [160, 190) → Tobamovirus altos
- Intervalo 4: [190, 240) → Furovirus

```
intervalos <- cut(
  total_residue,
  breaks = c(120, 148, 160, 190, 240),
  include.lowest = TRUE,
  right = FALSE
)

table(intervalos, grupo)
```

```
##            grupo
## intervalos  Furovirus Hordeivirus Tobamovirus Tobravirus
##   [120,148)         0           0           1          0
##   [148,160)         0           3          25          6
##   [160,190)         1           0          11          0
##   [190,240]        12           0           2          0
```

Tras dividir `total_residue` en cuatro intervalos, observamos que la mayoría de los Tobamoviruses se clasifican correctamente en su intervalo correspondiente.

No obstante, una parte de ellos (11 + 2 virus) presentan valores de residuos elevados, lo que puede inducir a error con los Furoviruses.

Este comportamiento era esperado según la descripción inicial del ejercicio, dado que un leve solapamiento entre grupos era inevitable debido a la variabilidad en la composición de aminoácidos.

Ejercicio 2

En este apartado y los siguientes vamos a trabajar únicamente con los Tobamoviruses.

Vamos a ir desglosando el enunciado paso a paso. En este punto, se nos indica que tenemos que trabajar únicamente con Tobamovirus, por lo tanto, vamos a extraerlo del vector generado en el ejercicio anterior en una variable

```
virus_tobamovirus <- virus[grupo == "Tobamovirus", ]
```

Recordar que hay dos virus con idénticas puntuaciones y únicamente incluiremos uno. Luego el primer paso es identificar y eliminar uno de los virus.

Para detectar si tenemos dos virus con idénticas puntuaciones, tenemos que buscar valores duplicados. Esto en R lo podemos realizar con la función "duplicated". Una vez aplicada esta función, vemos cuales son las filas duplicadas y eliminamos el valor duplicado para dejar sólamente uno

```r
duplicados <- duplicated(virus_tobamovirus)

which(duplicados)
```

```
## [1] 29
```

```r
virus_tobamovirus <- virus_tobamovirus[!duplicados, ]
```

Podemos observar en este caso que teníamos el número de fila 29 duplicado. Lo eliminamos con nuestro código para dejar sólamente un valor.

Realizar un análisis de componentes principales con los n = 38 virus del grupo Tobamovirus con las p = 18 características. Considerar las variables "tal cual" y repetir el análisis con las variables escaladas. Utilizar un máximo de 6 componentes. Realizar los gráficos y todas las explicaciones sobre este análisis.

Para hacer el PCA sin escalar, lo primero que tenemos que tener en cuenta es tener todos los datos numéricos. Vamos a hacer una comprobación previa con:

```r
str(virus_tobamovirus)
```

```
## 'data.frame':    38 obs. of  19 variables:
##  $ V1  : num  25 26 25 15 17 22 21 20 22 17 ...
##  $ V2  : num  9 9 9 10 11 17 18 9 10 13 ...
##  $ V3  : num  9 9 9 21 22 17 18 16 17 14 ...
##  $ V4  : num  19 20 22 13 15 16 15 15 18 16 ...
##  $ V5  : num  12 13 10 18 14 10 11 16 13 4 ...
##  $ V6  : num  8 8 10 12 10 15 15 6 6 9 ...
##  $ V7  : num  20 20 23 22 23 13 16 19 21 14 ...
##  $ V8  : num  0 0 0 1 1 1 1 1 1 1 ...
##  $ V9  : num  10 10 13 9 11 7 7 7 8 13 ...
##  $ V10 : num  0 0 0 2 2 2 2 3 3 0 ...
##  $ V11 : num  6 6 6 4 4 3 3 4 4 11 ...
##  $ V12 : num  21 21 19 11 11 14 14 14 13 13 ...
##  $ V13 : num  8 8 5 5 5 9 6 4 4 5 ...
##  $ V14 : num  7 7 6 10 9 9 8 11 11 7 ...
##  $ V15 : num  4 4 4 1 1 2 2 1 1 1 ...
##  $ V16 : num  7 7 8 14 13 12 12 16 15 4 ...
##  $ V17 : num  17 17 16 8 9 6 7 11 10 11 ...
##  $ V18 : num  5 5 5 2 1 2 2 3 3 5 ...
##  $ type: Factor w/ 4 levels "Hodr","Tobr",..: 1 1 1 2 2 2 2 2 2 3 ...
```

```r
#Vemos en este caso que, la variable type no es numérica, la excluímos para poder realizar nuestro anál

virus_tobamovirus <- virus_tobamovirus[, 1:18]
```

Realizamos el análisis de componentes principales para reducir la dimensionalidad de los datos, con ello, buscamos nuevas variables que capturen la mayor varianza de los datos con la menor cantidad de dimensiones. Primero vamos a hacer prcomp con datos no normalizados (sin escalar, incluyendo scale = FALSE y normalizados (escalados, incluyendo scale = TRUE)

```r
pca_sin_escalar <- prcomp(virus_tobamovirus, center = TRUE, scale. = FALSE)

# Vemos un resumen de PCA sin escalar
summary(pca_sin_escalar)
```

```
## Importance of components:
##                            PC1    PC2    PC3     PC4     PC5     PC6     PC7
## Standard deviation     7.1042 5.7103 4.1100 2.95778 2.40759 2.35687 1.98373
## Proportion of Variance 0.3768 0.2434 0.1261 0.06532 0.04328 0.04147 0.02938
## Cumulative Proportion  0.3768 0.6202 0.7464 0.81169 0.85497 0.89644 0.92582
##                            PC8     PC9    PC10    PC11    PC12    PC13   PC14
## Standard deviation     1.91671 1.40639 1.24345 1.05507 0.84718 0.66830 0.4337
## Proportion of Variance 0.02743 0.01477 0.01154 0.00831 0.00536 0.00333 0.0014
## Cumulative Proportion  0.95325 0.96802 0.97956 0.98787 0.99323 0.99656 0.9980
##                           PC15    PC16    PC17    PC18
## Standard deviation     0.37054 0.30378 0.18631 0.08940
## Proportion of Variance 0.00103 0.00069 0.00026 0.00006
## Cumulative Proportion  0.99899 0.99968 0.99994 1.00000
```

En este caso, con los datos sin escalar podemos observar que PC1 Y PCE 2 tienen la gran mayoría de varianza de los datos, un 62%

```r
pca_escalado <- prcomp(virus_tobamovirus, center = TRUE, scale. = TRUE)

# Resumen PCA escalado
summary(pca_escalado)
```

```
## Importance of components:
##                            PC1    PC2    PC3     PC4     PC5     PC6     PC7
## Standard deviation     2.2800 2.0955 1.7346 1.15504 1.00650 0.89107 0.78371
## Proportion of Variance 0.2888 0.2440 0.1671 0.07412 0.05628 0.04411 0.03412
## Cumulative Proportion  0.2888 0.5327 0.6999 0.77402 0.83030 0.87441 0.90854
##                            PC8     PC9    PC10    PC11    PC12    PC13    PC14
## Standard deviation     0.67062 0.55288 0.52447 0.48865 0.34548 0.30329 0.25551
## Proportion of Variance 0.02498 0.01698 0.01528 0.01327 0.00663 0.00511 0.00363
## Cumulative Proportion  0.93352 0.95050 0.96579 0.97905 0.98568 0.99079 0.99442
##                           PC15    PC16    PC17    PC18
## Standard deviation     0.20568 0.16668 0.12432 0.12213
## Proportion of Variance 0.00235 0.00154 0.00086 0.00083
## Cumulative Proportion  0.99677 0.99831 0.99917 1.00000
```

En el caso del PCA escalado, podemos ver que las variables están balanceadas y ninguna domina principalmente, haciendo la escalabilidad que todas las variables tengan aproximadamente el mismo peso

¿Cuales son las variables con mayor contribución a los dos primeros ejes en los dos análisis?

Para responder estas preguntas, tenemos que tener en cuenta que los componentes de cargas de las variables los podemos encontrar en rotation. Por ello, tenemos que mirar cuales serían sus valores absolutos y ver cuáles son los que más contribuyen

```r
# Valor rotation para PCA sin escalar
abs(pca_sin_escalar$rotation[, 1])  # pesos absolutos para ignorar el signo
```

```
##           V1           V2           V3           V4           V5           V6
## 0.0733924078 0.4334055968 0.3117898497 0.1141149156 0.2684636104 0.1701711157
##           V7           V8           V9          V10          V11          V12
## 0.4389793788 0.0231060184 0.1726751945 0.0005951624 0.2012687972 0.0741425803
##          V13          V14          V15          V16          V17          V18
## 0.0087124533 0.1395353662 0.0766959092 0.5480287378 0.0061916362 0.0253942391
```

```
abs(pca_sin_escalar$rotation[, 2])
```

```
##          V1          V2          V3          V4          V5          V6
## 0.321330989 0.034546215 0.628713599 0.442308238 0.133752016 0.118887550
##          V7          V8          V9         V10         V11         V12
## 0.054467441 0.007304069 0.133338469 0.052271587 0.051037750 0.271101339
##         V13         V14         V15         V16         V17         V18
## 0.139164243 0.161978589 0.148045269 0.163154616 0.237844318 0.149227782
```

Observando PCA sin escalar, vemos que la variable con mas peso para PC1 es V7, aportando un valor de 0.438, aunque V2 también proporciona un valor similar. Mientras tanto. en PC2 sería V3, aportando un 0,628

```
# Valor rotation para PCA escalado
abs(pca_escalado$rotation[, 1])
```

```
##         V1         V2         V3         V4         V5         V6         V7
## 0.29153925 0.25602856 0.05403728 0.12075866 0.28504797 0.24019151 0.27348521
##         V8         V9        V10        V11        V12        V13        V14
## 0.15780837 0.24273223 0.03686316 0.27360294 0.30600446 0.19200166 0.02098045
##        V15        V16        V17        V18
## 0.40114286 0.31907144 0.19210336 0.16614389
```

```
abs(pca_escalado$rotation[, 2])
```

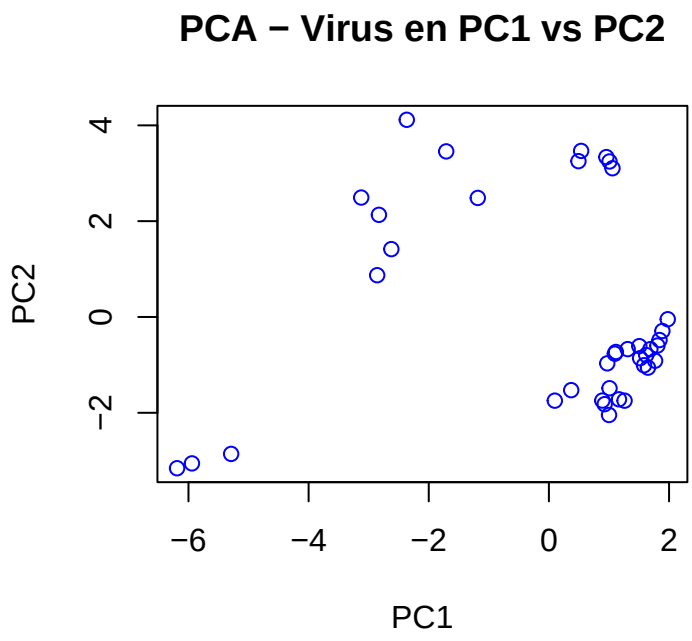
```
##         V1         V2         V3         V4         V5         V6         V7
## 0.14977876 0.19550895 0.40269898 0.35256520 0.16365673 0.06670402 0.23155698
##         V8         V9        V10        V11        V12        V13        V14
## 0.11493077 0.07298276 0.03240452 0.23585698 0.16662104 0.21262367 0.41035538
##        V15        V16        V17        V18
## 0.13214189 0.23082197 0.24365984 0.34833152
```

Para los valores escalados, podemos ver que tienen más peso los valores de V15 para PC1 (0,4) y V14 para PC2 (0,41), siendo los datos más similares por lo general.

¿Se observan algunas agrupaciones de los virus? ¿Cuantas?

Para poder observar agrupaciones, podemos verlo a través de gráficos. En este caso, utilizaremos plot para ver la distribución de los PCA escalados, poniendo en el eje x PC1 y en el eje Y PC2.

```
plot(
  pca_escalado$x[,1],
  pca_escalado$x[,2],
  xlab = "PC1",
  ylab = "PC2",
  main = "PCA - Virus en PC1 vs PC2",
  col = "blue"
)
```



Analizando el gráfico de dispersión de los virus en el plano definido por PC1 y PC2, se observan claramente dos agrupamientos principales:

- Un primer grupo, más compacto, situado en valores positivos de PC1 (aproximadamente entre 0 y 2).
- Un segundo grupo, más disperso, ubicado en valores negativos de PC1 (de -6 a 0), mostrando mayor variabilidad en PC2.

Esta separación sugiere la existencia de al menos dos subpoblaciones distintas de virus en el espacio de componentes principales.

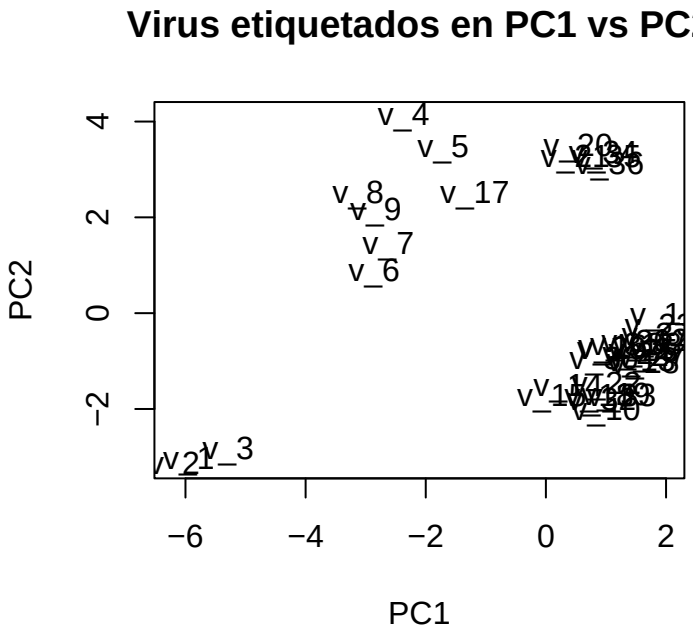
Identificar el virus que está entre dos grupos. Utilizar como etiquetas las originales de la base de datos completa. Ajustar el tamaño de las etiquetas para que sean visibles en el gráfico de dispersión.

Para poder identificar el virus concreto, tenemos que definir una variable que contenga el nombre de cada uno de los virus, utilizando los nombres que se nos proporciona en el dataframe. Esto lo podemos hacer con el siguiente código

```
nombres_tobamovirus <- paste0("v_", 1:38)

# Creamos el gráfico
plot(
  pca_escalado$x[,1],
  pca_escalado$x[,2],
  xlab = "PC1",
  ylab = "PC2",
  main = "Virus etiquetados en PC1 vs PC2",
  type = "n"
)
```

```r
# Añadimos las etiquetas
text(
  pca_escalado$x[,1],
  pca_escalado$x[,2],
  labels = nombres_tobamovirus,
)
```



Podemos observar que el virus que queda entre el grupo compacto y el grupo disperso es el tobamovirus_17.

Ejercicio 3

Realizar un análisis MDS clásico con la distancia euclídea entre los virus del grupo Tobamovirus y con las variables sin escalar. Dibujar el gráfico de dispersión en dos dimensiones y valorar el resultado.

Lo primero que vamos a realizar es un MSD clásico (Multidimensional Scaling clásico). Este análisis, nos permite representar datos en pocas dimensiones, respetando las distancias originales de nuestros datos. Por ello, como utilizaremos distancias, tenemos que empezar calculando la distancia euclídea

```r
# Calculamos la distancia euclídea y la introducimos dentro de una variable

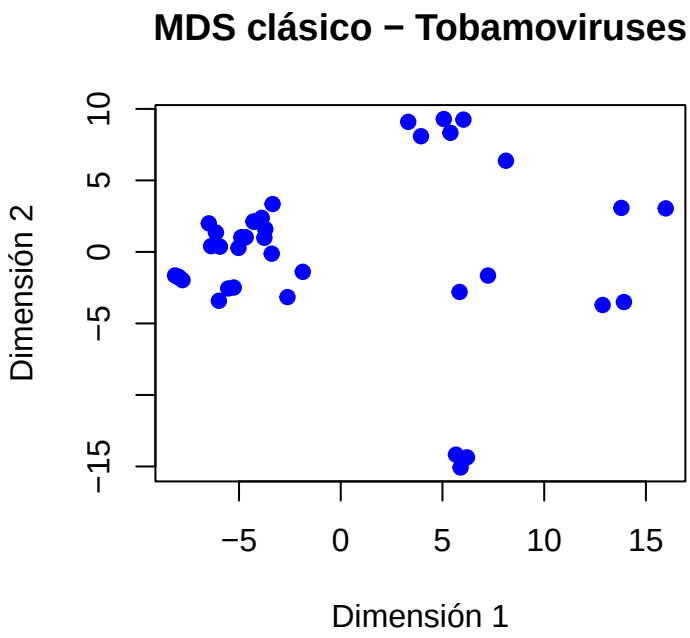
distancias <- dist(virus_tobamovirus, method = "euclidean")

#Posteriormente, realizamos el análisis MDS clásico con la distancia euclídea calculada

mds_clasico <- cmdscale(distancias, k = 2)
```

```r
# Representamos el gráfico de dispersión

plot(
  mds_clasico[,1],
  mds_clasico[,2],
  xlab = "Dimensión 1",
  ylab = "Dimensión 2",
  main = "MDS clásico - Tobamoviruses",
  pch = 19,
  col = "blue"
)
```

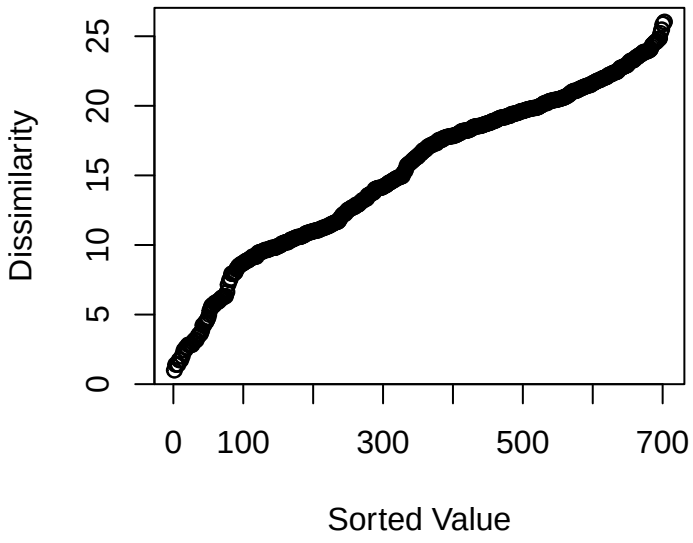


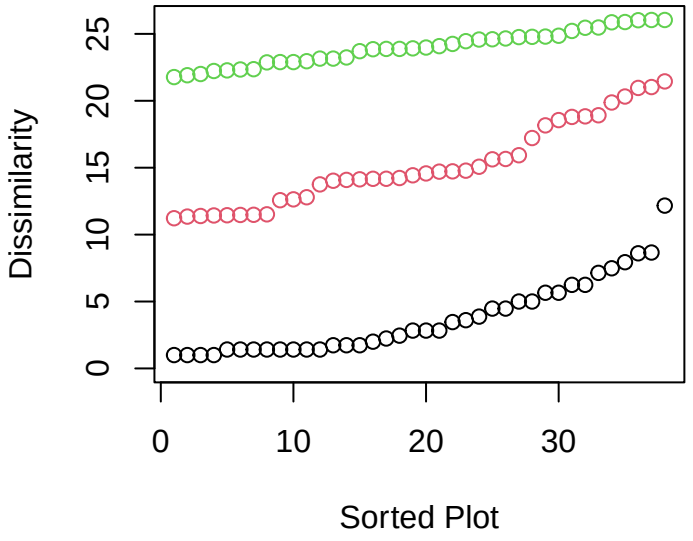
El gráfico de dispersión muestra una agrupación principal de virus en la parte izquierda del espacio, mientras que varios virus aparecen claramente dispersos y alejados, especialmente en el cuadrante derecho del gráfico.

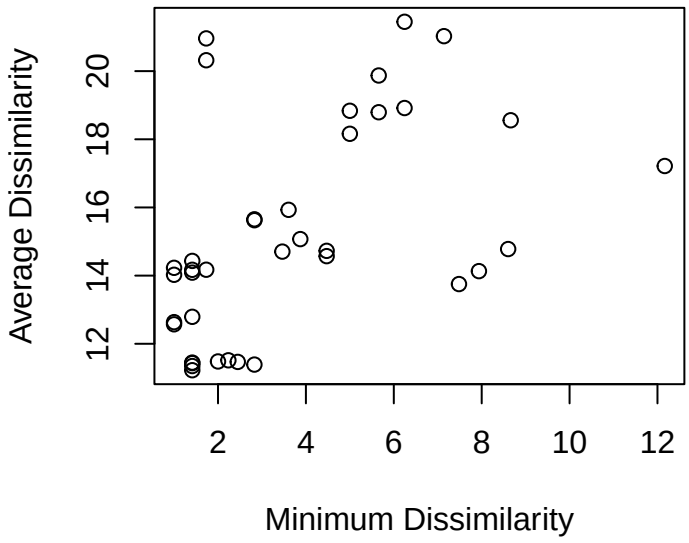
Estos virus aislados podrían representar casos atípicos o con características diferenciadas respecto al grupo central de Tobamoviruses.

Uno de los objetivos del estudio es hallar virus aislados o "alejados de cualquier grupo". Para ello podemos utilizar el gráfico mean vs minimum de la función disana() del paquete labdsv. Los puntos más a la derecha y arriba nos indican observaciones alejadas de cualquier grupo.

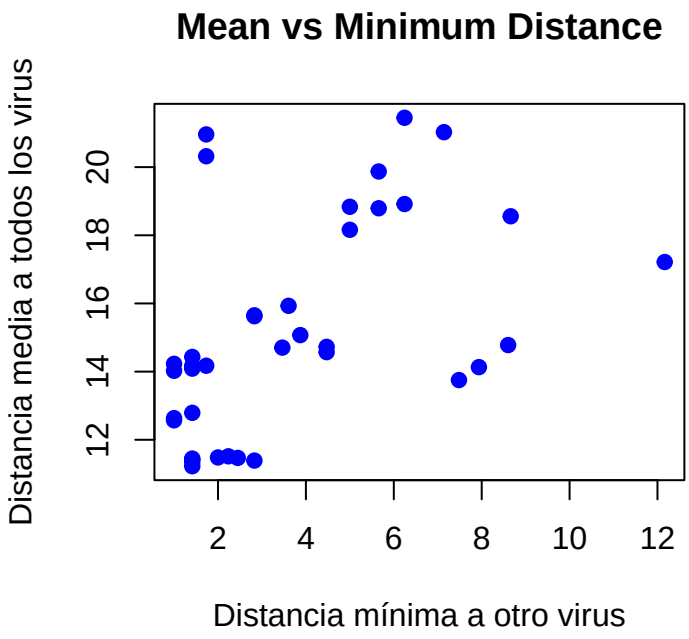
```r
library(labdsv)
```


Dissimilarity
0
5
10
15
20
25
0
100
300
500
700
Sorted Value


Dissimilarity
0
5
10
15
20
25
0
10
20
30
Sorted Plot




```
plot(
  resultado_disana$min,
  resultado_disana$mean,
  xlab = "Distancia mínima a otro virus",
  ylab = "Distancia media a todos los virus",
  main = "Mean vs Minimum Distance",
  pch = 19,
  col = "blue"
)
```



En este caso, pretendíamos usar la función disana del paquete labdsv, empaquetar en una variable la matriz generada anteriormente utilizando disana, que nos calcula la distancia mínima al virus más cercano y la distancia media a todos los virus. Posteriormente, sacábamos estas características para verlo de forma gráfica.

R no me carga el paquete labdsv, por lo que no puedo hacer una interpretación de este gráfico

Al exportar el archivo, puedo hacer una interpretación del gráfico. En este, podemos observar que los virus Tobamovirus se agrupan de manera cercana entre sí, aunque existe un número de virus que presentan aislamiento respecto a esta población agrupada. Esto puede indicar que existe, en este grupo de virus, variabilidad genética dentro del mismo grupo.

Ejercicio 4

Como las variables son puntuaciones no continuas, la distancia euclídea no parece la mejor elección. Entre las alternativas podemos considerar la distancia de Bray-Curtis. Realizar un MDS no métrico de Kruskal con la distancia de Bray-Curtis entre los virus del grupo Tobamovirus. ¿Por qué debemos realizar un MDS no métrico, mejor que un MDS métrico clásico?

```
library(vegan)
```

```
dist_bray <- vegdist(virus_tobamovirus, method = "bray")
```

```
nmds <- metaMDS(dist_bray, k = 2, trymax = 100)
```

```
## Run 0 stress 0.1435606
## Run 1 stress 0.1546141
## Run 2 stress 0.1593451
```

```
## Run 3 stress 0.1711908
## Run 4 stress 0.1435435
## ... New best solution
## ... Procrustes: rmse 0.01662481  max resid 0.09691184
## Run 5 stress 0.1777756
## Run 6 stress 0.1435435
## ... Procrustes: rmse 8.000367e-06  max resid 2.734609e-05
## ... Similar to previous best
## Run 7 stress 0.1435435
## ... Procrustes: rmse 2.576305e-06  max resid 1.133663e-05
## ... Similar to previous best
## Run 8 stress 0.1435606
## ... Procrustes: rmse 0.01662478  max resid 0.0975809
## Run 9 stress 0.1435606
## ... Procrustes: rmse 0.01662466  max resid 0.09758104
## Run 10 stress 0.1802218
## Run 11 stress 0.1775009
## Run 12 stress 0.1585173
## Run 13 stress 0.1435606
## ... Procrustes: rmse 0.01662418  max resid 0.09757839
## Run 14 stress 0.179997
## Run 15 stress 0.1792298
## Run 16 stress 0.1435606
## ... Procrustes: rmse 0.01662499  max resid 0.09758349
## Run 17 stress 0.1435606
## ... Procrustes: rmse 0.01662457  max resid 0.09758083
## Run 18 stress 0.1579399
## Run 19 stress 0.1734814
## Run 20 stress 0.177501
## *** Best solution repeated 2 times
```

En este caso, para nuestros estudios, la distancia no era lo más acertado debido a que la distancia euclídea supone magnitudes comparables y diferencias absolutas. Si hacemos una comparativa con Bray-Curtis, este propone diferencias relativas entre las muestras sin verse afectadas por magnitudes. Por lo general, Bray-Curtis se suele utilizar para datos como recuentos, puntuaciones o proporciones.

Basándonos en esto, debemos realizar un MDS no métrico, ya que nuestra medición no es estríctamente métrica y se basa en proporciones, permitiendonos representar las relaciones entre los virus y conservando los rangos de similitud.

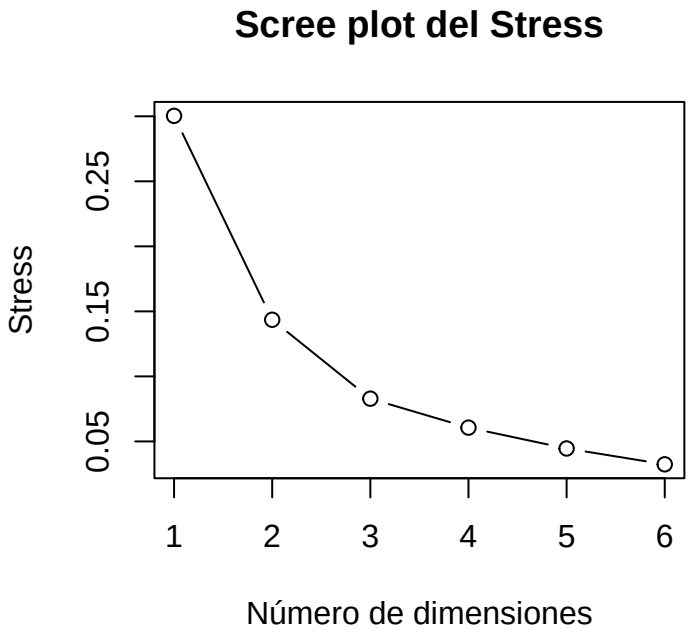
Dibujar un scree plot sobre el stress para evaluar el número de ejes a considerar. Dibujar también un gráfico de Shepard para comparar las distancias originales y las propuestas por el MDS no métrico con 2 dimensiones. ¿Cuantos subgrupos vemos en el gráfico de dispersión con 2 dimensiones?

```r
stress_values <- NULL

for (k in 1:6) {
  nmds_k <- metaMDS(dist_bray, k = k, trymax = 50, trace = FALSE)
  stress_values <- c(stress_values, nmds_k$stress)
}

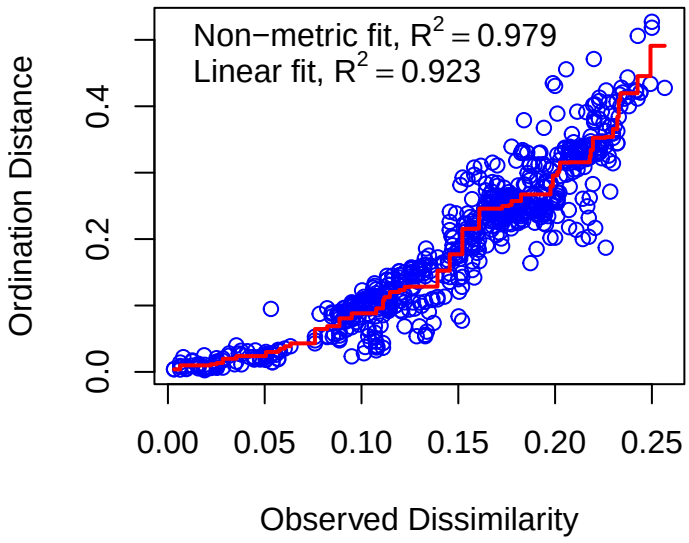
plot(
  1:6, stress_values,
  type = "b",
```

```
  xlab = "Número de dimensiones",
  ylab = "Stress",
  main = "Scree plot del Stress"
)
```



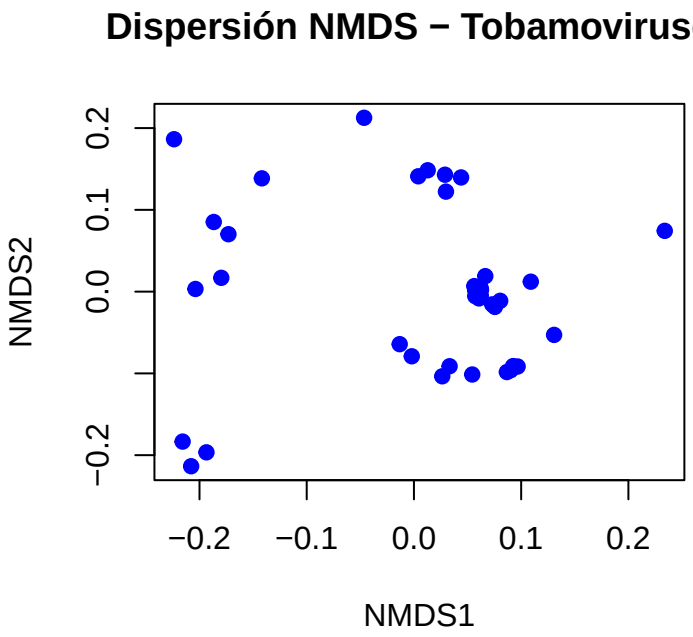
En este caso, podemos observar los valores de Stress en función del número de dimensiones. Podemos ver según el scree plot que después de 2 dimensiones, la curva comienza a aplanarse. Esto nos indica que 2 dimensiones son suficientes para representar bien las relaciones entre los virus Tobamovirus en el NMDS.

```
stressplot(nmds)
```



Segun el gráfico de Shepard, tenemos una alta correspondencia entre las disimilitudes y las distancias proyectadas al espacio. Por ello, el modelo NMDS corresponde con las distancias originales entre los virus Tobamovirus

```
plot(
  nmds$points[,1],
  nmds$points[,2],
  xlab = "NMDS1",
  ylab = "NMDS2",
  main = "Dispersión NMDS - Tobamoviruses",
  pch = 19,
  col = "blue"
)
```



El gráfico de dispersión de los virus Tobamovirus en el espacio NMDS1-NMDS2 nos muestra un subgrupo principal compacto, formado por virus similares entre sí, junto con algunos virus más dispersos.

Por tanto, podemos identificar al menos dos subgrupos: uno mayoritario compacto y otros pocos individuos más alejados.

El gráfico Shepard previamente nos ha mostrado una correspondencia entre las disimilitudes y las distancias, por lo que tenemos un buen ajuste de este gráfico

Ejercicio 5

Realizar un mapa no lineal de Sammon, es decir, otro tipo de MDS no métrico con la distancia de Bray-Curtis y los datos de Tobamovirus. Dibujar los gráficos del apartado anterior y responder las mismas cuestiones.

```
library(vegan)
dist_bray <- vegdist(virus_tobamovirus, method = "bray")
```

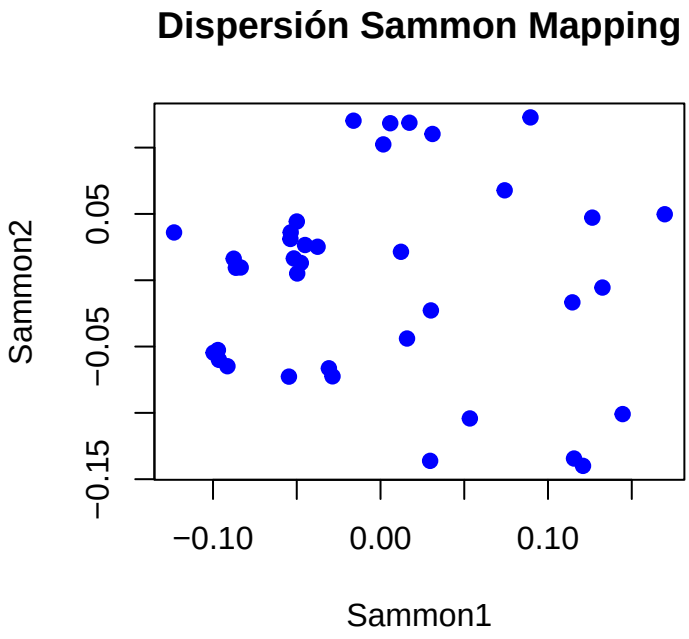
```
library(MASS)
sammon_result <- sammon(dist_bray, k = 2)
```

```
## Initial stress        : 0.13457
## stress after  10 iters: 0.06550, magic = 0.018
## stress after  20 iters: 0.05083, magic = 0.500
## stress after  30 iters: 0.04977, magic = 0.500
## stress after  40 iters: 0.04958, magic = 0.500
## stress after  50 iters: 0.04944, magic = 0.500
## stress after  60 iters: 0.04930, magic = 0.500
## stress after  70 iters: 0.04920, magic = 0.500
```

En este caso, vamos a realizar lo que se conoce como "Sammon Mapping". Consiste en una técnica de reducción de dimensionalidad no lineal. Se diferencia del MDS no métrico porque intenta presercar proporcionalmente las distancias pequeñas mucho más que las grandes, por lo que asegura que puntos muy cercanos en el espacio original, sigan estando muy cerca en la representación original.

Como mencionamos anteriormente, para estos métodos no métricos, no podemos utilizar la distancia euclídea, si no que utilizamos la distancia Bray-Curtis. En este caso, como estamos utilizando la librería vegan, utilizamos vegdist para calcular la distancia y le especificamos el método que queremos. Con la librería MASS ya podríamos realizar nuestro método de sammon. En este caso, trabajamos directamente con dos dimensiones (K=2) para representar los datos en un espacio bidimensional

```
plot(
  sammon_result$points,
  xlab = "Sammon1",
  ylab = "Sammon2",
  main = "Dispersión Sammon Mapping",
  pch = 19,
  col = "blue"
)
```




```
sammon_result$stress
```

```
## [1] 0.0492043
```

La representación de Sammon nos muestra una concentración principal de virus en torno a 0.0, indicando una gran similitud en estos puntos. Por otro lado, de nuevo, vemos algunos grupos de virus diferenciados de forma más aislada. Esto, coincide con los grupos que habíamos obtenido en el NMDS no métrico.

Ejercicio 6

Ejercicio 7

Otra distancia que se utiliza mucho con puntuaciones o frecuencias es la distancia ji-cuadrado. Comprobar que la matriz D de esta distancia sobre los datos de Tobamovirus verifica que

$$\mathbf{B = -\,1/2\ H(D \times D)H}$$

es semidefinida positiva y, por lo tanto, la distancia es euclídea. La matriz H es la matriz de centrado. Realizar un MDS con esta distancia y comentar el resultado respecto a los ejercicios anteriores.

Como hemos visto en ejercicios anteriores, la librería vegan, al tratarse de distancia, nos puede facilitar mucho los cálculos mientra le especifiquemos el método con el que vamos a trabajar.

```
library(vegan)
dist_chi <- vegdist(virus_tobamovirus, method = "chisq")
```

Posteriormente, definimos las variables de la ecuación

```
# Ecuación

D <- as.matrix(dist_chi)

D_squared <- D^2

n <- nrow(D_squared)

H <- diag(n) - (1/n) * matrix(1, n, n)

B <- -0.5 * H %*% D_squared %*% H
```

```
eigen_B <- eigen(B)

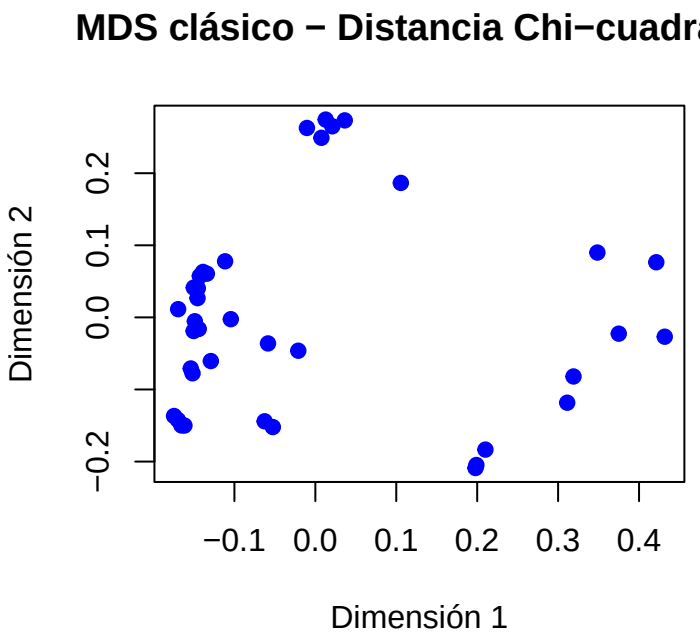
eigen_B$values
```

```
##  [1]  1.387864e+00  7.091051e-01  5.218745e-01  2.312704e-01  1.820275e-01
##  [6]  9.931756e-02  8.217093e-02  6.811824e-02  4.647439e-02  3.793203e-02
## [11]  2.793748e-02  2.257335e-02  1.350580e-02  8.035847e-03  4.647754e-03
## [16]  3.194566e-03  2.164171e-03  1.901826e-16  9.746803e-17  7.029127e-17
## [21]  5.259824e-17  3.985781e-17  2.880457e-17  2.719109e-17  1.140954e-17
## [26]  1.038415e-17  7.722195e-18 -4.278494e-18 -4.650725e-18 -8.625298e-18
## [31] -1.004817e-17 -1.098785e-17 -1.975033e-17 -3.976659e-17 -4.054021e-17
## [36] -5.183353e-17 -7.086251e-17 -9.856911e-17
```

Al calcular los autovalores de la matriz, se observa que los valores principales son positivos y los valores negativos que aparecen son extremadamente pequeños. Estos valores negativos pequeños pueden deberse a errores de redondeo. Estos errores son despreciables a efectos prácticos, por lo que concluímos que la distancia chi-cuadrado es euclídea y se puede utilizar un MDS clásico para su representación

```
mds_chi <- cmdscale(dist_chi, k = 2, eig = TRUE)
```

```r
plot(
  mds_chi$points[,1],
  mds_chi$points[,2],
  xlab = "Dimensión 1",
  ylab = "Dimensión 2",
  main = "MDS clásico - Distancia Chi-cuadrado",
  pch = 19,
  col = "blue"
)
```



Este gráfico con chi-cuadrado de distancia cuadra con los estudios que hemos hecho previamente, ya que podemos observar un grupo principal compacto, que se encuentra en los valores -0.1 y 0.1 de la dimensión 2 y algunos virus dispersos en la dimensión 1, lo que indica la existencia de subgrupos

Ejercicio 8

Realizar un análisis de correspondencias. Calcular la inercia total con los valores propios y las primeras inercias principales (en %).

Dibujar una representación simétrica del CA y una representación solo de los virus.

Comparar el resultado con el obtenido con la distancia ji-cuadrado.

```r
library(ca)
```

```r
ca_result <- ca(virus_tobamovirus)
```

Vamos a realizar un análisis de correspondencias sobre los virus Tobamovirus. Para ello, utilizaremos la librería ca. Aplicamos el análisis de correspondencia a nuestra variable virus_tobamovirus. Con este análisis

de correspondencia podemos calcular los valores propios, ya que se obtiene con el cuadrado de los valores singulares, la inercia total (suma de todos los valores propios) y el porcentaje de inercia.

```
# Valores propios
valores_propios <- (ca_result$sv)^2

# Inercia total
inercia_total <- sum(valores_propios)
inercia_total
```

```
## [1] 0.09434463
```

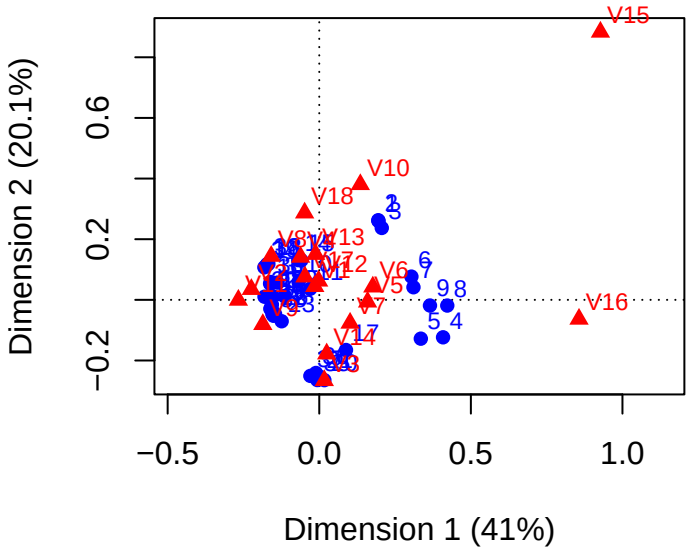
```
# Porcentajes de inercia principal
porcentajes <- 100 * valores_propios / inercia_total
porcentajes
```

```
##  [1] 40.99534140 20.12538314 15.73048653  6.65640095  5.02904756  2.74258530
##  [7]  2.27200840  1.89161812  1.30709567  1.01153430  0.73622606  0.63381622
## [13]  0.36831306  0.22611839  0.12585692  0.08871036  0.05945760
```

En cuanto a los resultados, podemos observar que las dos primeras dimensiones tienen alrededor de un 60% de inercia total, por lo que, es un valor bastante bueno ya que demostramos que el 60% de la variabilidad de los datos puede ser representado en 2D.

Por último, vamos a hacer la representación simétrica y la representación de los virus

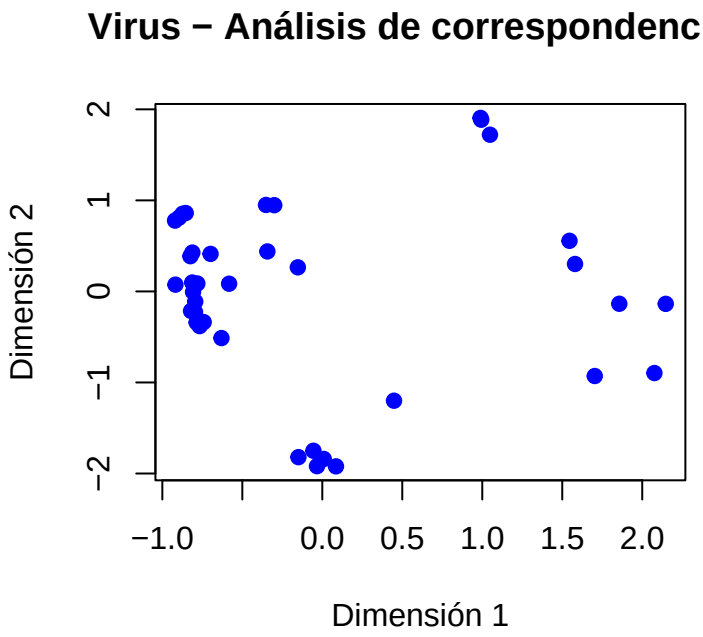
```
#Representación simétrica
plot(ca_result)
```



Con la representación simétrica, podemos observar que algunos residuos como V15 y V16 se encuentran bastante alejados, indicando que están asociados a algunos virus más extremos. Los residuos más cercano están agrupados de manera bastante compacta, lo que indica asociación con virus.

```
#Representación de los virus

plot(
  ca_result$rowcoord[,1],
  ca_result$rowcoord[,2],
  xlab = "Dimensión 1",
  ylab = "Dimensión 2",
  main = "Virus - Análisis de correspondencias",
  pch = 19,
  col = "blue"
)
```



Realizando la comparativa con chi cuadrado, vemos que obtenemos un gráfico del que podemos obtener conclusiones similares, ya que ambas representaciones nos enseñan una estructura de datos caracterizada por subgrupos principales de virus y algunos virus dispersos

Ejercicio 9

Realizar un brevísimo informe con las conclusiones sobre la formación de grupos con los datos de Tobamovirus que se deducen de los ejercicios anteriores.

A partir de los diversos análisis multivariantes que hemos realizado (MDS no métrico, Sammon Mapping, MDS clásico, chi cuadrado y análisis de correspondencia) sobre los datos que teníamos respecto a Tobamovirus, hemos detectado algunos patrones que pueden ayudar a estudiar el virus de una forma más fidedigna.

Hemos observado que existe un subgrupo principal de virus Tobamovirus que, en todos los análisis realizados, aparecede forma muy compácta y homogénea.

Sin embargo, este no era el único subgrupo, debido a que aparecen varios virus más dispersos que se alejan de este grupo principal. Esto, nos muestra que pueden existir poblaciones más pequeñas y heterogeneas que difieren de este subgrupo compacto y homogéneo.

En cuanto a la fiabilidad, estudios en 2D representan bastante bien la variabilidad de estos análisis ya que la inercia en estas dos dimensiones es aproximadamente de un 61%. Analizando también el valor bajo de stress en NMDS y el Sammon mapping, vemos que las distancias son fieles a las distancias originales entre virus.

Por ello, podemos concluir que, según los estudios realizados en este trabajo, existen uno o dos subgrupos principales de virus (dependiendo de si tienen una variabilidad natural o son una subpoblación emergente) que presentan una alta similitud interna, acompañado de algunos virus diferenciados.